

Classificação automática de arritmia em sinais de ECG utilizando Redes Neurais de Grafos baseado em classificação de grafos

Rafael Francisco de Oliveira
rafael.fo@aluno.ufop.edu.br

Universidade Federal de Ouro Preto - UFOP

16 de dezembro de 2021

① Introdução

② Conjunto de dados

③ Metodologia

④ Resultados

⑤ Conclusão

⑥ Referências

INTRODUÇÃO




Figura 1: Pontos fiduciais de um sinal ECG (CLIFFORD et al., 2006).

- Paradigmas de classificação automática de sinais ECG:
 - *Intra-patient*: sinais de um mesmo paciente é utilizado na construção e no teste do modelo de classificação.
 - **Inter-patient*: um conjunto de sinais é utilizado na construção do modelo e outro conjunto é utilizado para testá-lo.
- *A melhor opção para simulação de um cenário real.

CONJUNTO DE DADOS

- MIT-BIH Arrhythmia Database (MOODY; MARK, 1990);
- Desenvolvido pelo MIT e Boston's Beth Israel Hospital;
- 48 sinais obtidos de 47 pacientes entre 1975-1979;
- Cada sinais tem 30 minutos selecionados de uma gravação de 24 horas;
- Amostrados a 360Hz em 2 canais (V and II);
- 04 gravações apresentam batimentos sintéticos.

Tabela 1: Mapeamento entre MIT-BIH e AAMI¹

Classe MIT-BIH	Classe AAMI	batimentos
Normal beat (N or .)	Normal (N)	90082
Left bundle branch block beat (L)		
Right bundle branch block beat (R)		
Atrial escape beat (e)		
Nodal (junctional) escape beat (j)		
Atrial premature beat (A)	Supraventricular ectopic beat (S)	2781
Aberrated atrial premature beat (a)		
Nodal (junctional) premature beat (J)		
Supraventricular premature beat (S)		
Premature ventricular contraction (V)		
Ventricular escape beat (E)	Ventricular ectopic beat (V)	7008
Fusion of ventricular and normal beat (F)	Fusion beat (F)	802
Paced beat (P or /)	Unknown beat (Q)	15
Fusion of paced and normal beat (f)		
Unclassified beat (U)		
Unknown beat (Q)		
TOTAL		100688

¹Association for the Advancement of Medical Instrumentation

Tabela 2: Descrição do número de amostras antes e depois do balanceamento de dados.

Batimentos	Treinamento		Teste	
	Antes	Depois	Antes	Depois
N	45844	3000	44238	3000
S	944	944	1837	1837
V	3788	3788	3220	3220
Total	50576	7732	49295	8057

Conjuntos	Sinais de ECG
DS1 (Treinamento)	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223, and 230.
DS2 (Teste)	100, 103, 105, 111, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233, and 234.

Tabela 3: Distribuição do conjunto de dados do MIT-BIH proposto por (CHAZAL; O'DWYER; REILLY, 2004)

*AAMI recomenda a exclusão dos sinais com batimentos sintéticos (102,104,107,217).

METODOLOGIA

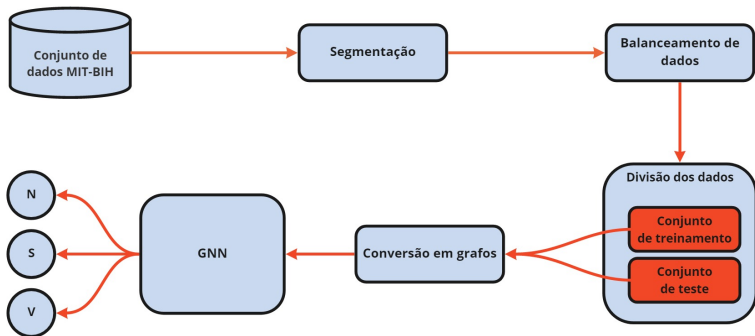


Figura 2: Metodologia proposta.




Figura 3: Exemplo de segmentação de sinal ECG (WANG et al., 2021).


















Figura 4: Exemplo de uma série temporal periódica (20 valores) e o grafo derivado pelo método *visibility graph* (LACASA et al., 2008)

Metodologia

Visibility graph



Metodologia

Graph Neural Network (GNN)

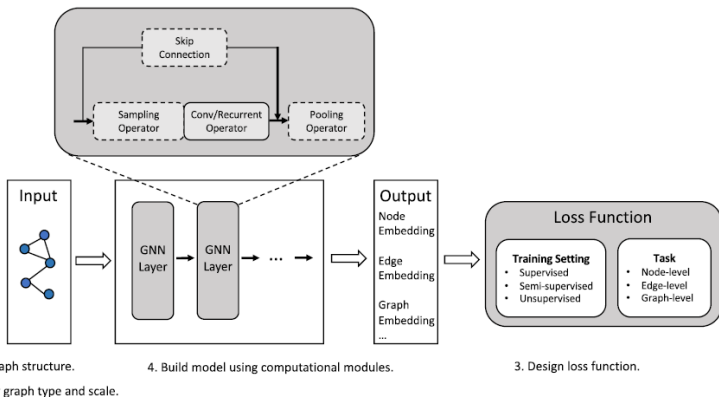


Figura 5: Pipeline geral de um modelo GNN. (ZHOU et al., 2020).

Atributos de cada nó do grafo: [grau, *pagerank*].

Tabela 4: Arquiteturas de cada modelo avaliado de rede GNN ava.

Modelos	No	Camada	Formato
<i>02 GCN</i>	1	GraphConv	2×20
	2	GraphConv	20×3
	3	Readout	-
	4	Softmax	-
<i>03 GCN</i>	1	GraphConv	2×20
	2	GraphConv	20×20
	3	GraphConv	20×3
	4	Readout	-
	5	Softmax	-
<i>04 GraphSAGE</i>	1	SAGEConv	2×30
	2	SAGEConv	30×20
	3	SAGEConv	20×5
	4	SAGEConv	5×3
	5	Readout	-
	6	Softmax	-

RESULTADOS

$$+P^k = \frac{TP^k}{TP^k + FP^k} \times 100 \quad (\text{Predição positiva}) \quad (1)$$

$$Se^k = \frac{TP^k}{TP^k + FN^k} \times 100 \quad (\text{Sensibilidade*}) \quad (2)$$

$$F_s^k = 2 \frac{Se^k(+P^k)}{Se^k + (+P^k)} \quad (\text{F1-score}) \quad (3)$$

Tabela 5: Matrizes de confusão do conjunto de teste (DS2) para cada modelo proposto.

Modelos		Matrizes de confusão			
02 GCN	Verdade	Predição			
		N	S	V	
		1725	5	1270	
		194	57	1586	
	V	388	12	2820	
03 GCN	Verdade	Predição			
		N	S	V	
		2813	9	178	
		170	129	1538	
	V	388	40	2792	
04 GraphSAGE*	Verdade	Predição			
		N	S	V	
		2953	1	46	
		5	355	1477	
	V	33	395	2792	

Tabela 6: Performance dos modelos em relação ao conjunto de teste (DS2).

Modelos	Acc	N			S			V		
		+P ^N	Se ^N	F _s ^N	+P ^S	Se ^S	F _s ^S	+P ^V	Se ^V	F _s ^V
02 GCN	57	75	57	65	77	3	6	50	88	63
03 GCN	71	83	94	88	72	7	13	62	87	72
04 GraphSAGE*	76	99	98	99	47	19	27	65	87	74




Figura 6: Curva da acurácia durante o treinamento dos modelos ao longo de 100 épocas.

Resultados

Função de perda (*loss*)




Figura 7: Curva da função perda (*loss*) durante o treinamento dos modelos ao longo de 100 épocas.

CONCLUSÃO

- A acurácia nem sempre consegue descrever bem a performance do modelo.
- 04 *GraphSAGE* foi o melhor modelo.
- Potencial das Redes Neurais de Grafos.
- Possibilidade de extração de informações inerentes dentro do grafo.
- Propostas de Redes neurais de Grafos mais robustas.
- Agregação de mais informações nos grafos.

REFERÊNCIAS



CHAZAL, P. D.; O'DWYER, M.; REILLY, R. B. Automatic classification of heartbeats using ecg morphology and heartbeat interval features. *IEEE transactions on biomedical engineering*, IEEE, v. 51, n. 7, p. 1196–1206, 2004.



CLIFFORD, G. D. et al. *Advanced methods and tools for ECG data analysis*. [S.l.]: Artech house Boston, 2006.



LACASA, L. et al. From time series to complex networks: The visibility graph. *Proceedings of the National Academy of Sciences*, National Acad Sciences, v. 105, n. 13, p. 4972–4975, 2008.



MOODY, G. B.; MARK, R. G. The mit-bih arrhythmia database on cd-rom and software for use with it. In: IEEE. [1990] *Proceedings Computers in Cardiology*. [S.l.], 1990. p. 185–188.



WANG, T. et al. Automatic ecg classification using continuous wavelet transform and convolutional neural network. *Entropy*, Multidisciplinary Digital Publishing Institute, v. 23, n. 1, p. 119, 2021.



ZHOU, J. et al. Graph neural networks: A review of methods and applications. *AI Open*, Elsevier, v. 1, p. 57–81, 2020.

Obrigado!

