

Reconhecimento automático de padrões de arritmia em sinais de ECG utilizando Discrete Wavelet Transform com SMOTE

Rafael Francisco de Oliveira

Departamento de Computação

Universidade Federal de Ouro Preto - UFOP

Conselho Nacional de Desenvolvimento Científico e Tecnológico - CNPq

Email: rafael.fo@aluno.ufop.edu.br

Abstract—O processo de identificação e classificação de doenças cardiovasculares (DCVs), especialmente as arritmias em eletrocardiogramas (ECGs) pode ser muito exaustivo para um ser humano e, sujeito a erros, uma vez que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. A automatização desse processo torna-se desejável e atualmente, diversas técnicas de inteligência artificial têm sido aplicada. Neste estudo, com o objetivo de obter um diagnóstico preciso dos tipos de DCVs, de acordo com a arritmia em batimentos cardíacos de ECG, um modelo de classificação automática de arritmias em ECG é proposto baseado em *Discrete Wavelet Transform* - (DWT) com função geradora db14. São avaliados quatro classificadores: *XGradientBoost*, *GradientBoost*, *Support Vector Machine* e *Rede Neural Artificial*. Os modelos são avaliados no conjunto de dados PhysioNet MIT-BIH de acordo com os padrões da AAMI com o uso do paradigma *inter-patient* no desenvolvimento metodológico e experimental. Dentre as métricas analisadas, a sensibilidade *Se* foi a de maior peso de avaliação. O modelo *Gradient Boost* foi o que apresentou o melhor desempenho em relação às classes minoritárias S e V, obtendo 49% e 62% de *Se*, respectivamente. O modelo *XGradient Boost* apresentou a melhor *Se* de 71% para a classe N.

Keywords: Classificação; AAMI; Discrete Wavelet Transform; Arritmia; SVM; Eletrocardiograma; Inter-Patient; Redes neurais artificiais.

I. INTRODUÇÃO

De acordo com a Organização Mundial de Saúde (OMS), doenças cardíacas são a principal causa de morte no planeta. Embora boa parte das doenças cardíacas possam ser diagnosticadas com antecedência, o número de casos continua a crescer. Estima-se que mais de 75% dos casos acontecem em países pobres e em desenvolvimento e 17,9 milhões de pessoas morreram de doenças cardíacas em 2019, representando 32% das mortes globais [1]. Isso se deve ao fato de que, medidas de prevenção, aparentemente, não estão sendo adequadas, por isso o diagnóstico precoce é de fundamental importância.

O principal exame para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG). Segundo Cohen [2], o ECG foi um dos primeiros sinais estudados pelas técnicas de processamento de sinais biomédicos e até os dias de hoje é a técnica mais utilizada no diagnóstico de doenças do coração.

Isto é possível por causa da simplicidade do exame, o qual é um processo não-invasivo.

Um dos problemas cardíacos detectável pelo exame de ECG são as arritmias. Arritmias são batimentos cardíacos anormais ou irregulares. Há duas categorias de arritmias: as arritmias formadas por um único batimento cardíaco irregular, denominadas de arritmias morfológicas, e as arritmias formadas por um conjunto irregular de batimentos, denominadas arritmias rítmicas.

O processo de identificação e classificação de arritmias pode ser muito exaustivo para um ser humano e, ainda sujeito a erros, visto que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. Portanto, existe a necessidade de estudos por soluções que mitigue esses erros. Uma alternativa consiste no uso de inteligência artificial para classificação automática dos padrões de arritmia. Atualmente, métodos baseados em aprendizagem de máquina, do inglês *machine learning*, tornaram-se bastante populares, obtendo resultados expressivos [3]. Porém, ainda há muito espaço para melhorias, especialmente quando se considera uma avaliação mais rigorosa [4].

Uma grande dificuldade para o uso em campo prático de técnicas estado-da-arte, como as baseadas em aprendizagem de máquina, é a sua integração com os equipamentos médicos. Para que as soluções propostas possam ser utilizadas em monitores de sinais vitais ou desfibriladores, por exemplo, o projeto e análise de experimentos deve obedecer a norma ANSI/AAMI EC57:1998/(R)2008 [4] da *Association for the Advancement of Medical Instrumentation (AAMI)*. Além disso, deve-se seguir outras normas e boas práticas de desenvolvimento para construção de software para equipamentos médicos-hospitalares. Manter a conformidade com todas as normas e boas práticas é ainda um grande obstáculo para a introdução de novas técnicas na indústria. As abordagens publicadas na literatura que não seguem esses requisitos tendem a ser superestimados e assim, sem grande valor prático para fabricantes de equipamentos médicos [5].

O processo de classificação de arritmias divide-se em quatro partes principais: pré-processamento, segmentação do sinal, extração de características e classificação. Na etapa de pré-

processamento, são aplicados filtros com o objetivo de eliminar a interferência de ruídos no sinal ECG, o que afeta diretamente a acurácia de modelos propostos. A etapa de segmentação é realizada através da detecção das ondas R (Fig. 1) de cada sinal. Após a detecção, o sinal é dividido em batimentos com tamanho fixo pré-estabelecido. Na etapa de extração de características, são propostos diversos métodos na literatura, dentre eles a *Discrete Wavelet Transform (DWT)*, que permite obter uma representação multirresolução dos padrões da estrutura do sinal no domínio tempo-frequência. Em seguida, aplica-se algum método classificador, o qual é treinado utilizando as características extraídas do sinal.

Neste projeto, propõe-se a classificação automática de arritmia a partir de sinais de ECG. Para isso, a técnica DWT é utilizada nas etapas de pré-processamento e extração de características e a classificação é realizada por meio de quatro classificadores: *XGradientBoost*, *GradientBoost*, *Support Vector Machine - SVM* e *Rede Neural Artificial - ANN*. A proposta é uma análise comparativa entre os desempenhos de cada modelo. Pretende-se, ainda, seguir as normas ANSI/AAMI EC57:1998/(R) para o desenvolvimento metodológico e experimental. Os experimentos foram validados utilizando o *dataset PhysioNet MIT-BIH* [6], [7] através do paradigma *inter-patient* proposto por De Chazal et al. [8].

O trabalho é organizado como segue. Seção II mostra uma breve revisão da literatura referente às etapas necessárias para um sistema de classificação de ECG, bem como os métodos existentes. Seção III define o conjunto de dados utilizado para avaliação do modelo. A metodologia proposta para a classificação de ECG é descrita na Seção IV. Além disso, na Seção V, a descrição dos experimentos e resultados são mostrados. Na Seção VI, as discussões dos resultados obtidos e comparações com outros trabalhos da literatura são apresentados. Finalmente, as observações finais são reportadas na Seção VII.

II. TRABALHOS RELACIONADOS

Um sistema completo de classificação e reconhecimento de arritmias em ECG pode ser dividido em quatro partes principais: 1) pré-processamento, 2) segmentação do sinal, 3) extração de características e 4) classificação.

Para melhor extração das informações úteis do sinal, algumas técnicas são aplicadas. A etapa de pré-processamento refere-se a etapa de tratamentos dos sinais de ECG, como por exemplo, normalização e remoção de ruído (interferência na linha de energia e *baseline wandering*). Diversos métodos tem sido propostos na literatura, como filtros-bandas [9], [10], métodos baseados em *wavelet transform* [11], [12], filtros adaptativo [13], [14], decomposição empírica [15], e análise de componente independente [16]. Deve-se observar o uso excessivo de filtros, pois pode ocasionar a perda de informações úteis para a classificação.

T. Wang et al. [17] e Dias et al. [18] utilizaram dois filtros de média móvel, um deles com largura de 200 ms e outro com largura de 600 ms para remoção do *baseline wandering* do sinal, ocasionado pela respiração ou pelo movimento do

paciente. L. Wang et al. [12] propuseram um método de seleção *wavelet* com limiar adaptativo para redução de ruído em ECG baseado em funções *wavelet*. O limiar foi ajustado dinamicamente utilizando heurística e o número de camadas da decomposição da função *wavelet*. Blanco-Velasco et al. [19] utilizaram modo de decomposição empírica para remoção de altas frequências de ruídos e *baseline wandering*. Em [20], a decomposição adaptativa de Fourier foi escolhida para diminuição o ruído dos sinais de ECG.

A detecção de arritmias com base na classificação de ECG tornou-se um tópico de pesquisa muito popular na literatura nos últimos anos [5]. Os métodos tradicionais utilizam características extraídas do sinal para a classificação dos batimentos cardíacos, como, por exemplo, o intervalo RR, coeficientes *wavelets*, amplitude, complexo QRS, onda P, duração, etc. Os principais pontos e intervalos, denominados de pontos fiduciais, de um sinal ECG são mostrados na Fig. 1. Dentre os pontos apresentados, temos o segmento QRS, o qual normalmente é utilizado durante o processo de segmentação de um sinal de ECG em batimentos menores.




Fig. 1: Batimento normal de ECG da derivação II [21].

Após a aplicação dos filtros no pré-processamento, segmentam-se os batimentos individuais do sinal de ECG. Isso requer detecção das ondas QRS e pontos fiduciais dos batimentos [17]. No entanto, trabalhos na literatura não executam essa etapa e usam a posição da onda R rotulada no conjunto de dados [5]. Uma abordagem diferente é proposta por Ye et al [22], onde propuseram a adição sintética de um tremor (*jitter*) na posição da onda R. O tremor é modelado com média zero e desvio padrão de 5 amostras, isto é, 13,9 ms.

A identificação dos sinais ocorre a partir de características extraídas dos sinais de ECG. Com isso, várias características e métodos têm sido utilizados na literatura em diversas propostas. De Chazal et al [8] combinaram características rítmicas, duração de onda e características morfológicas. Zheng et al [23] utilizaram mais de 200 características no clas-

sificador utilizado, tais como idade, gênero, características do canal II do ECG além de características extraídas dos 12 canais presente no banco de dados utilizado. L. Wang et al. [12] propuseram um método de seleção de características baseado em transformação *wavelet* com limiar adaptativo, visando reduzir o ruído do sinal de ECG. Rakshit e Das [15] propuseram uma metodologia utilizando o modo de decomposição empírica (*empirical mode decomposition (EMD)*) e filtro de comutação média adaptativa (*adaptive switching mean filter (ASMF)*) para decompor os sinais ECG, gerando um conjunto de funções intrínsecas (*intrinsic mode functions (IMFs)*) com base na complexidade do sinal para remoção da interferência do ruído.

A *Wavelet Transform* pode ser utilizada para extração de características, uma vez que a mesma realiza uma decomposição adaptativa em tempo-frequência do sinal de ECG. Pela representação multirresolução é possível descrever a estrutura do sinal por apenas alguns coeficientes do domínio *Wavelet* [24]. A Fig. 2 exemplifica a decomposição de um sinal ECG em dez sub-bandas de frequências diferentes.




Fig. 2: Representação de multirresolução de um sinal ECG pelos coeficientes *wavelet* [24].

Os métodos de classificação que utilizam técnicas de aprendizagem de máquina apresentam limitações de performance quando lidam com conjuntos de dados desbalanceados. Em particular, esses conjuntos de dados atingem um valor preditivo positivo baixo. Além disso, baixa sensibilidade para as classes com menor quantidade de amostras, ocasionando em resultados enviesados. Adicional ao problema de conjuntos de dados desbalanceados, métodos que não levam em consideração normas de separação de dados em conjuntos de treinamento e teste tendem a obter resultados altos e enviesados.

Com o objetivo de tornar o modelo em desenvolvimento mais robusto e adaptável a um cenário no mundo real, alguns trabalhos na literatura exploraram dois paradigmas de validação de dados: *intra-patient* e *inter-patient* [25]. No paradigma *intra-patient*, o conjunto de treinamento e teste é formado por dados de um mesmo paciente, enquanto que no

paradigma *inter-patient*, proposto por De Chazal et al. [8], o conjunto de treinamento e teste são obtidos de pacientes diferentes. Esse último permite uma generalização mais próxima de um cenário do mundo real.

Mousavi e Afghah [25] propuseram um modelo baseado em redes neurais de aprendizado profundo (*deep learning*) aplicado com metodologia *sequence to sequence* e algoritmo SMOTE para balanceamento das classes durante a etapa de treinamento. Os autores avaliaram o modelo com trabalhos estado-da-arte da literatura de acordo com os paradigmas apresentados anteriormente. O modelo proposto obteve performance superior em relação a todos os trabalhos comparados, em ambos paradigmas, obtendo acurácia de 99,92% no paradigma *intra-patient* e 99,53% no paradigma *inter-patient*.

Para melhor avaliação do desempenho real do classificador, garantindo uma competição justa entre modelos propostos na literatura e seguir práticas recomendadas pela AAMI [4], alguns trabalhos [8], [10], [18], [26] fizeram uso do paradigma *inter-patient* com o mesmo objetivo. Logo, este trabalho propõe o uso do mesmo paradigma no desenvolvimento metodológico.

Após a extração das características do sinal de ECG, um classificador de aprendizado de máquina é treinado utilizando as características do sinal. A escolha do classificador ocorre de acordo com o problema a ser tratado. Na literatura há vários modelos, tais como SVM [27], random forest [26], AdaBoost [28], XGBoost [29] e redes neurais artificiais [30].

O modelo de redes neurais artificiais apresenta crescente interesse pela comunidade científica, pois uma de suas vantagens é a capacidade de generalização e aplicações. Porém, os padrões encontrados no treinamento dos modelos precisam prover uma caracterização suficientemente eficiente para que se adapte à entrada de novos dados.

III. CONJUNTO DE DADOS

Em razão das propostas de modelos de classificação para o avanço da instrumentação médica [4], foi utilizado o conjunto de dados de arritmias PhysioNet MIT-BIH [6], [7], [31] para treinamento e validação da metodologia proposta, permitindo assim uma possível comparação com outras metodologias da literatura. O conjunto de dados do MIT-BIH é composto por 48 registros de sinais de ECG de 30 minutos de 47 pacientes diferentes amostrados a frequência de 360 Hz. Cada sinal contém duas derivações: derivação V e derivação II. Normalmente, a derivação II é a mais utilizada nas metodologias da literatura. De forma similar, nos experimentos deste trabalho, a derivação II foi utilizada.

Seguindo recomendações da AAMI, quatro registros [102, 104, 107 e 217] são excluídos do conjunto de dados por conter batimentos artificiais. De Chazal et al. [8] recomenda a divisão do conjunto de dados em dois conjuntos: treinamento (DS1) e teste (DS2) conforme a Tabela I. Essa divisão faz parte do paradigma *inter-patient* utilizado neste trabalho, onde o conjunto de treinamento e teste apresentam conjuntos de registros diferentes.

O conjunto de dados do MIT-BIH contém informações dos tipos de batimentos e a localização do pico R, mediante o consenso de classificação de dois cardiologistas. Dentre os 18 tipos de batimentos, a AAMI também recomenda o agrupamento dos batimentos em cinco grupos principais: *Normal (N)*, *Supraventricular ectopic beat (S)*, *Ventricular ectopic beat (V)*, *Fusion beat (F)* e *Unknown beat (Q)*. A Tabela II resume o agrupamento dos batimentos dos dados do MIT-BIH após a exclusão dos registros com batimentos artificiais bem como o número de amostras do conjunto de treinamento e teste. Observa-se que as classes F e Q apresentam poucos batimentos, somando menos de 0,81% de presença em relação ao conjunto de dados total. Por esse motivo, as classes F e Q são removidas, sendo os modelos aplicados apenas às classes N, S e V.

Tabela I: Distribuição dos registros do MIT-BIH em conjunto de treinamento e teste.

Conjunto	Registros
DS1 (treinamento)	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223, e 230.
DS2 (Teste)	100, 103, 105, 111, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233, e 234.

IV. METODOLOGIA

A seguir, é apresentado a metodologia proposta para classificação automática de arritmias em ECG. O diagrama da Fig. 3 mostra as etapas do sistema de classificação proposto: pré-processamento, segmentação, extração de características e classificação.

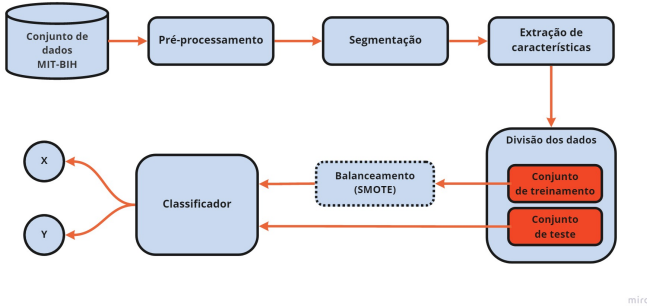


Fig. 3: Diagrama do sistema de classificação de arritmia.

A. Pré-processamento

O conjunto de dados do MIT-BIH é bastante desbalanceado e o número de batimentos amostrados de cada grupo de arritmia são completamente diferentes, conforme mostra a Tabela II. Este desbalanceamento causa sobreajuste (*overfitting*) no modelo de classificação em relação a classe majoritária e subajuste (*underfitting*) das classes minoritárias,

ou seja, diminuição da acurácia das predições das classes minoritárias. Por outro lado, há ainda a presença de ruídos e/ou interferências nos sinais de ECG causados, por exemplo, por movimento do corpo ou cabos de energias defeituosos, os quais prejudicam a performance de extração de características e classificação do modelo. Outro desafio, diz respeito a extração de batimentos dos sinais de ECG. Na etapa de pré-processamento, utiliza-se de três processos para contornar os problemas apresentados anteriormente.

1) *Normalização*: de modo geral, a normalização é o processo que visa ajustar os valores medidos em diferentes escalas de um determinado conjunto de dados para uma escala comum. Os valores dos sinais ECG foram normalizados aplicando o método de normalização Z-score. Este método utiliza a média e desvio padrão para normalização dos dados de acordo com a fórmula 1, resolvendo assim, o problema de amplitude dimensionando e eliminando os efeitos de deslocamento,

$$x' = \frac{x - \bar{x}}{\sigma} \quad (1)$$

onde x é o valor do sinal original, \bar{x} é a média dos valores do sinal e σ é o desvio padrão dos valores do sinal.

2) *Sobreamostragem*: para solucionar o problema do alto desbalanceamento do conjunto de dados do MIT-BIH, é utilizado a técnica *Synthetic Minority Over-sampling Technique - SMOTE* nas classes minoritárias. O SMOTE utiliza a similaridade entre as amostras existentes para produção dos dados sintéticos. Para isso, a classe minoritária é super-amostrada tomando cada amostra de classe minoritária e introduzindo exemplos sintéticos de qualquer e/ou todos os k vizinhos mais próximos da classe minoritária k de forma randômica [32]. Portanto, após as etapas de pré-processamento, o SMOTE é aplicado no conjunto de treinamento (DS1). Para evitar sobreamostragem irregular, a técnica SMOTE é aplicada de forma diferente para cada classe, sendo a classe N sub-amostrada em 69,46% e as classes S e V sobreamostradas em 4137% e 956%, respectivamente conforme descrito na Tabela III. O SMOTE é aplicado apenas no conjunto de treinamento.

Tabela III: Descrição do número de amostras antes e depois da sobreamostragem SMOTE no conjunto de treinamento.

Tipo de batimentos	Amostragem	
	Antes	Depois
N	45844	15000
S	944	40000
V	3788	40000
Total	50576	95000

3) *Remoção de ruído*: sinais de ECG apresentam diversos ruídos provenientes de diversas formas, como movimentos dos músculos, da respiração do paciente ou mau contato dos elétrodos na pele do paciente, os quais podem diminuir a acurácia do modelo. Para isso, foi aplicada a técnica *Discrete Wavelet Transform (DWT)* baseada em *thresholding*.

Tabela II: Agrupamento de tipos de batimento no conjunto de dados do MIT-BIH.

Grupo AAMI	Batimentos	% do total	# Treinamento (DS1)	# Teste (DS2)	# Batimentos total
<i>Normal (N)</i>	N, e, j, L, R	89,47	45844	44238	90082
<i>Supraventricular ectopic beat (S)</i>	A, a, J, S	2,76	944	1837	2781
<i>Ventricular ectopic beat (V)</i>	V, E	6,96	3788	3220	7008
<i>Fusion beat (F)</i>	F	0,80	414	388	802
<i>Unknown beat (Q)</i>	P, f, U, Q	0,01	8	7	15
Total		100	50998	49690	100688

Wavelet Transform (WT) é uma série composta por operações de escalonamento e deslocamento em base de uma função geradora chamada de *mother wavelet*, podendo ser contínuas ou discretas. WT pode representar uma informação local do sinal de ECG no domínio do tempo e frequência para ajustar as sub-bandas de alta e baixa frequência separadamente através da janelas de tempo e de frequência, para atingir o objetivo de eliminação de ruído dos sinais de ECG [12]. WT tem sido utilizada em diferentes metodologias, como detecção de batimentos [33] e extração de características [34].

A *Continuous Wavelet Transformation (CWT)* realiza o escalonamentos e deslocamentos de forma contínua enquanto que a *Discrete Wavelet Transform (DWT)* realiza as operações de forma discreta. As fórmulas (2) e (3) [35] representam as funções contínuas e discretas, respectivamente:

$$X_w(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \bar{\psi}\left(\frac{t-b}{a}\right) dt \quad (2)$$

$$\psi_{j,k}(t) = \frac{1}{\sqrt{2^j}} \psi\left(\frac{t - k2^j}{2^j}\right) \quad (3)$$

onde $x(t)$ é o sinal original, $\bar{\psi}(t)$ é a função *wavelet* contínua, $[(a > 0) a \in \mathcal{R}^{+*}, j]$ são fatores de escalonamento e $[b, j]$ são fatores de deslocamento. Como a CWT tem alta correlação, a DWT é mais utilizada nas aplicações de redução de ruídos [12], a qual é utilizada nesse trabalho.

A DWT decompõe o sinal de ECG iterativamente, e em cada iteração, o sinal é decomposto a partir do valor médio da frequência do sinal de entrada. Para isso, utiliza-se de filtros de passagem alta (FPA) e filtros de passagem baixa (FPB). A Fig. 4 exemplifica o processo de decomposição de um sinal em duas camadas da WT.




Fig. 4: Processo de decomposição do sinal em duas camadas [12].


O sinal de entrada S_0 é filtrado na sub-banda de alta frequência D_1 e na sub-banda de baixa frequência A_1 , e então a A_1 é filtrado novamente em sub-bandas de alta e

baixa frequência, D_1 e D_2 , respectivamente. O processo de decomposição do sinal S_0 pode ser resumido pela fórmula (4):

$$S_0 = D_1 + D_2 + A_2 \quad (4)$$

Após a decomposição, os coeficientes podem perceber sinal de amplitude maiores do que o ruído em certa medida, definida pelo limiar (*threshold*). Valores acima desse limiar são removidos, reduzindo assim, os ruídos do sinal original. A Fig. 5 mostra o diagrama para o método de remoção de ruídos utilizando *thresholding*. As três principais etapas são:

- (i) **Decomposição:** consiste na determinação dos coeficientes de baixa e alta frequências e o nível no qual o *threshold* é aplicado na DWT. Ainda, determina-se qual a função wavelet e o nível de decomposição do sinal.
- (ii) **Thresholding:** determinado os coeficientes, um *threshold* é escolhido para eliminar todos os valores abaixo do mesmo. Nessa etapa é possível ainda escolher entre *threshold* suave ou *threshold* rígido.
- (iii) **Reconstrução:** por último, após a eliminação dos ruídos, os coeficientes resultantes, o nível e a wavelet são utilizados na reconstrução. Finalmente obtém-se um sinal com redução de ruídos.

Fig. 6: Exemplo do processo de filtragem utilizando DWT com *thresholding* em um sinal de ECG.

Neste trabalho, utilizou-se a função wavelet *sym20* para a redução de ruído com um *thresholding* de 0.4 devido sua alta correspondência com o segmento QRS do sinal de ECG. A

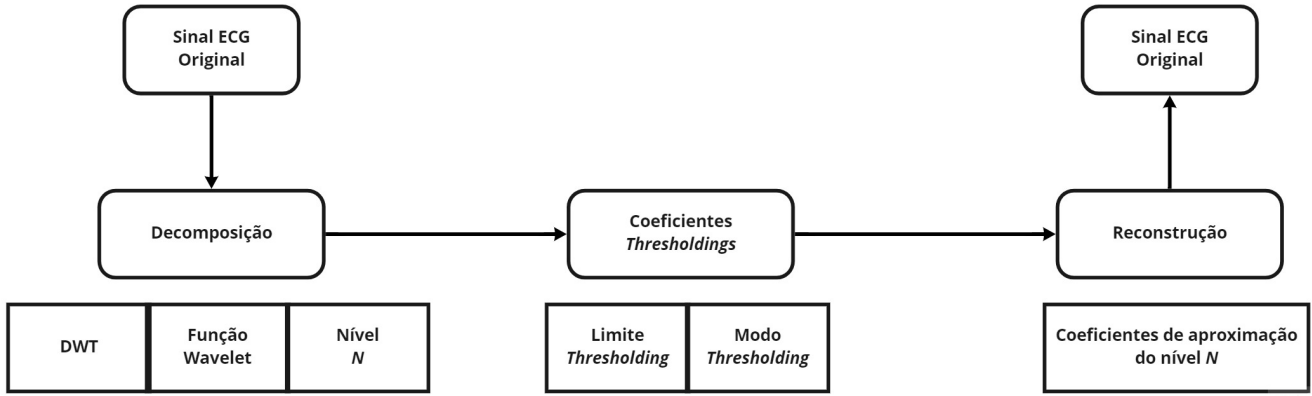


Fig. 5: Diagrama de remoção de ruídos em sinais de ECG [36].

aplicação do método de remoção de ruídos utilizando a função *sym20* com *thresholding* em um segmento de sinal ECG é mostrada na Fig. 6. Como pode-se perceber, ao desconstruir o sinal, atenuar alguns dos coeficientes e reconstruí-lo novamente, o sinal é suavizado com a diminuição dos ruídos do sinal de ECG.

B. Segmentação

Antes da classificação, é necessário a segmentação do sinal ECG em batimentos individuais. Isto requer a identificação da onda QRS e pontos fiduciais do batimento. No entanto, vários métodos são desenvolvidos na literatura para detecção desses pontos fiduciais com altas acurácias. Uma ilustração do processo de segmentação é mostrada na Fig. 7. Neste processo de segmentação, foi utilizado a localização do pico R anotada no conjunto de dados do MIT-BIH, segmentando o sinal em séries de batimentos extraíndo 150 amostras antes e 150 amostras depois do pico R, e realizando o registro do tipo de batimento de acordo com as anotações do MIT-BIH. No final, cada batimento obteve tamanho fixo de 300 amostras do sinal de ECG.

C. Extração de características

Os batimentos são compostos por diferentes frequências. Por isso, nessa etapa de extração de características, os batimentos são convertidos para o domínio tempo-frequência utilizando a DWT. Como os diferentes tipos de batimentos exibem características de frequência diferentes, essa diferença de comportamento é capaz de gerar características para cada batimento, as quais posteriormente tornam-se um vetor de características para entrada de um classificador. A função *db14* foi utilizada no processo de extração de características por ser semelhante a onda R presente em cada batimento. A função *db14* gera 4 sub-bandas diferentes para cada batimento. Em cada sub-banda são extraídas 14 características, conforme as descritas pela Tabela IV, totalizando 56 características para cada sinal. *Zero crossing* e *mean crossing* significa quantas vezes o sinal cruzou ($y = 0$) e $y = \text{media}(y)$, respectivamente.




Fig. 7: Exemplo de segmentação de sinal ECG [17].

Kurtosis e *skewness* medem quão leve ou pesada são as caudas e quão assimétricos são os valores da distribuição do conjunto de dados em relação a uma distribuição uniforme, respectivamente.

Tabela IV: Conjunto de características extraídas de cada batimento de ECG.

CARACTERÍSTICAS	
• 5-percentil	• 25-percentil
• 75-percentil	• 95-percentil
• mediana	• média
• desvio padrão	• variância
• média quadrática	• entropia
• zero crossing	• mean crossing
• kurtosis	• skewness

D. Classificação

Após aplicar todas as etapas de pré-processamento, segmentação e extração de características, as características obtidas são enviadas para um classificador. Nesse trabalho, são abordados quatro classificadores: *XGradientBoost*, *Gradient-Boost*, *Support Vector Machine (SVM)* e *Rede Neural Artificial (ANN)*.

1) *Support Vector Machine*: Proposto por Vapnik [37], SVM são métodos que constroem classificadores a partir da criação de hiper-planos em um espaço n -dimensional, isto é, desenha “linhas” em um espaço n -dimensional que são capazes de separar exemplos de diferentes classes [38], [39]. Estes hiper-planos são criados com o auxílio de pontos localizados nas bordas dos conjuntos, chamados *vetores de suporte*.

O SVM constrói primeiramente um hiperplano ou um conjunto de hiperplanos em um espaço n -dimensional. Uma separação ideal entre os dados é obtida através do hiperplano que possui a maior distância ao ponto de dados de treinamento mais próximo de qualquer classe, denominada de *margin funcional*. Isso ocorre, porque quanto maior a margem, menor o erro de generalização do classificador.

Normalmente, os dados em análise não são facilmente separáveis em hiperplanos, uma vez que os dados, em sua maioria, são não-lineares. Como solução, propõe-se que os dados em espaço original sejam mapeados em um hiper espaço n -dimensional ou espaço em dimensão superior para facilitar a separação dos dados.

Os mapeamentos usados pelos esquemas SVM são projetados para garantir que os produtos escalares de pares de vetores de dados de entrada possam ser calculados facilmente em termos das variáveis no espaço original, definindo-as em termos de uma função *kernel* $k(x, y)$.

Os hiperplanos no espaço de dimensão superior são definidos como o conjunto de pontos cujo produto escalar com um vetor naquele espaço é constante, onde tal conjunto de vetores é um conjunto ortogonal de vetores que define um hiperplano.

Os vetores que definem os hiperplanos podem ser escolhidos para serem combinados linearmente com parâmetros α_i dos vetores de características x_i do conjunto de dados. Escolhido o hiperplano, os pontos x no espaço de características são mapeados no hiperplano pela equação:

$$\sum_i \alpha_i k(x_i, x) = \text{constant} \quad (5)$$

Quando $k(x, y)$ na Equação (5) torna-se pequeno à medida que y torna-se longe de x , cada termo na soma mede o grau de proximidade do ponto de teste x ao ponto do conjunto de dados correspondente x_i .

Desta forma, a soma da Equação (5) pode ser usada para medir a proximidade relativa de cada ponto de teste aos pontos de dados originados em um ou outro conjunto a ser discriminado.

2) *Redes Neurais Artificiais (ANN)*: Pode-se pensar nas ANNs como sendo um sistema computacional contendo um

grande número de neurônios artificiais. Por sua vez, estes neurônios podem ser vistos como processadores simples, massivamente paralelizados e organizados de forma inspirada a uma rede neural biológica. Esses neurônios artificiais também podem ser generalizados para melhor atender às necessidades de um problema em específico, formando-se diversas arquiteturas de redes.

As arquiteturas mais utilizadas para classificação de arritmias são *Multilayer Perceptron (MLP)* e *Probabilistic Neural Network (PNN)*. Esses tipos de redes podem ser combinados a fim de maximizar a eficiência da classificação. Há trabalhos que propuseram, por exemplo, uma rede híbrida neuro-fuzzy [40] e redes neurais otimizadas evolucionárias com *particle swarm optimization (PSO)* [41].

Redes neurais permitem adaptação de forma mais específica de acordo com o problema através da organização das camadas intermediárias e funções de ativações dentro da rede. Este tipo de rede também permite realizar a transformação necessária e as operações de agrupamento automática e simultaneamente e reconhecer grupos complexos e não lineares no hiperespaço. Apesar dessas vantagens, redes neurais requerem tempo de processamento, *hardware* e grande conjunto de dados dependendo do tipo de problema em estudo.




Fig. 8: Rede neural artificial com um neurônio.

Formalmente, todos os tipos de redes neurais apresentam a mesma unidade de processamento: um neurônio artificial. Esse neurônio artificial possui várias entradas, que correspondem às conexões sinápticas com outras unidades similares a ele, e uma saída, cujo valor depende diretamente da somatória ponderada de todas as saídas dos outros neurônios a esse conectado.

Pela Fig. 8 mostra uma rede neural artificial de um neurônio, onde as constantes de ponderação w_i representam as conexões sinápticas biológicas que intermeiam a interação entre neurônios vizinhos, x_i é o estímulo proveniente do neurônio vizinho i , e o somatório \sum representa o estímulo global (com as devidas ponderações relativas) recebido pelo neurônio de todos os seus vizinhos.

De acordo com o valor da variável somatório \sum e com a função de ativação $f()$ à qual essa variável é aplicada, a rede fornece uma saída em resposta aos estímulos x_i conforme representado pela equação:

$$y = f\left(\sum_{i=1}^m x_i w_i\right) \quad (6)$$

Uma rede neural artificial com vários neurônios é exemplificada na Fig. 9. A rede apresentada contém uma camada

de entrada com 4 neurônios, uma camada oculta_1 com 5 neurônios, outra camada oculta_2 com 7 neurônios e por último, uma camada com 3 neurônios. A rede fornecerá três saída $[y_1, y_2, y_3]$ de acordo com a resposta dos estímulos de entrada $[x_1, x_2, x_3, x_4]$ ao longo da rede dado pela Equação (6).




Fig. 9: Rede neural artificial com vários neurônios.

3) *GradientBoost e XGradientBoost*: Algoritmos de aprendizagem de máquina combinados (*Ensembles*) são modelos compostos que combinam uma série de classificadores de baixo desempenho com o objetivo de criar um classificador aprimorado, ou seja, são meta-algoritmos que combinam vários métodos de aprendizado de máquina em um único modelo preditivo para aumentar o desempenho. Os algoritmos combinados podem diminuir a variância utilizando a abordagem de ensacamento (*bagging*), reforço (*boosting*) e empilhamento (*stacking*). Os modelos

Os algoritmos de *boosting* são um conjunto do classificador de baixa precisão para criar um classificador de alta precisão. O classificador de baixa precisão oferece uma precisão melhor do que jogar uma moeda. O classificador altamente preciso (ou classificador forte) oferece uma taxa de erro próxima de 0. O algoritmo de *boosting* pode rastrear o modelo que falhou na previsão precisa. Esses algoritmos podem ser menos afetados pelo problema de sobreajuste do modelo (*overfitting*). Os modelos *XGradientBoost* e *GradientBoost* fazem parte desse grupo de algoritmos.

Os modelos são ajustados usando qualquer função de perda diferenciável e arbitrária (*loss function*) e algoritmo de otimização de gradiente descendente (*gradient descent*). Isso dá à técnica o nome de “reforço de gradiente” (*gradient boosting*), já que o gradiente de perda é minimizado conforme o modelo é ajustado, de forma semelhante ao utilizado em uma rede neural.

V. RESULTADOS

A. Configurações

Os experimentos foram conduzidos em um ambiente Linux Mint 20 e Python 3.8 com Intel®i9-10900 com 10 cores físicos

(20 threads) de 2.80GHz, 128GB RAM DDR4 e GPU RTX 3090 de 24GB de RAM GDDR6X.

Como medida de avaliação dos modelos propostos, três métricas fora utilizadas: predição positiva ($+P^k$), sensibilidade (Se^k) e F1-score (F_s^k).

As métricas são baseadas nas medidas de verdadeiro positivo (TP^k), falsos negativos (FN^k), verdadeiros negativos (TN^k) e falsos positivos (FP^k), de acordo com as Fórmulas 8, 7 e 9.

$$+P^k = \frac{TP^k}{TP^k + FP^k} \times 100 \quad (7)$$

$$Se^k = \frac{TP^k}{TP^k + FN^k} \times 100 \quad (8)$$

$$F_s^k = 2 \frac{Se^k(+P^k)}{Se^k + (+P^k)} \quad (9)$$

onde $k \in \{N, S, V\}$ indica as classes correspondente de cada métrica. Como a proposta do modelo é a classificação correta de todos os batimentos de acordo com as determinadas classes, a sensibilidade (Se) teve maior peso diante da escolha do melhor classificador, uma vez que a mesma concede uma medida de quão preciso o modelo é capaz de identificar os dados relevantes.

B. Resultados

Para cada classificador, o conjunto de treinamento (DS1) foi dividido utilizando *10-fold cross-validation* pelo método *StratifiedKfold* da biblioteca *Scikit-learn* do python. Este método permite que a divisão de *folds* ocorra preservando o percentual de amostras de cada classe. A validação cruzada (*cross-validation*) com *10-fold* utiliza *9-folds* como treinamento e *1-fold* como teste, realizando a variação dos *folds* a cada iteração. Posteriormente, o classificador é treinado novamente no conjunto de treinamento, dessa vez com todas as amostras e validado no conjunto de teste (DS2).

Ainda, cada modelo é analisado em dois contextos: o primeiro com o conjunto de dados normalizado e com aplicação do SMOTE e o segundo com o conjunto de dados originais e sem aplicação do SMOTE. Esses contextos permitem verificar a eficiência dos modelos de classificação diante dos tratamentos de dados propostos. A análise é realizada considerando os resultados do conjunto de teste.

VI. DISCUSSÕES

A. Support Vector Machine

Para avaliação do modelo *SVM* foi utilizada a biblioteca *Scikit-learn* do python. Essa biblioteca apresenta diversos hiperparâmetros, parâmetros utilizados para controlar o processo de aprendizado do modelo, os quais não são “aprendidos” durante o processo de treinamento. Dentre esses hiperparâmetros, dois apresentam grande influência no desempenho do *SVM*: o parâmetro de regularização (C) e o coeficiente de kernel (γ). A técnica utilizada para estimar os melhores valores para esses parâmetros foi a *RandomizedSearchCV*

da biblioteca *Scikit-learn*. Essa biblioteca realiza uma busca randômica entre um intervalo de valores para cada hiperparâmetro, retornando o melhor resultado de acordo com alguma métrica específica. Há ainda, a biblioteca *GridSearchCV* que realiza o mesmo processo de otimização, porém a busca é realizada no conjunto formado pela combinação de todos os valores do intervalo de busca, portanto quanto maior o intervalo e o conjunto de dados, maior o tempo de processamento.

Utilizando a busca pelo método *RandomizedSearchCV* através de 200 iterações, os melhores valores encontrados para os hiperparâmetros foram $C = 13,4$ e $\gamma = 0,2$ e $\text{kernel} = \text{rbf}$, dentro dos intervalos de busca $[0, 1, 100]$, $[0, 01, 10]$ e $[\text{rbf}, \text{poly}]$, respectivamente. As Tabelas V e VI mostram as matrizes de confusão do *SVM* para o conjunto de teste original e aplicado ao SMOTE, respectivamente.

Tabela V: Matriz de confusão do conjunto de teste original para o *SVM*.

Verdade	Predição			
		N	S	V
	N	44238	0	0
	S	1837	0	0
	V	3220	0	0

Tabela VI: Matriz de confusão do conjunto de teste aplicado ao SMOTE para o *SVM*.

Verdade	Predição			
		N	S	V
	N	743	1	43494
	S	12	0	1825
	V	123	0	3097

O desempenho do *SVM* não foi satisfatório mesmo com a aplicação do SMOTE no conjunto de dados. A Tabela V mostra que o modelo classificou todas as classes como sendo pertencentes à classe N, classificando erroneamente as classes S e V. Isso faz com que a sensibilidade (Se) e a predição positiva ($+P$) das classes S e V sejam iguais a zero. O cenário apresenta um melhor desempenho em relação à V, Se^V de 96%, porém prejudica o desempenho para a classe N com a aplicação do SMOTE no conjunto de dados. A classe S continua sem nenhuma melhora de acordo com Tabela VI.

Diante da metodologia proposta, percebe-se que o SMOTE demonstrou uma melhora significativa no desempenho para a classe V, indo de nenhuma predição correta para 3097 predições corretas. Por outro lado, o SMOTE ocasionou uma queda no desempenho em relação às classes N de 98,32% relacionado às predições positivas. Quanto a classe S, não houve melhora, permanecendo sem nenhuma predição correta.

B. Gradient Boost

Para este modelo, o único hiperparâmetro configurado manualmente foi $n_estimator = 200$, indicando o número de iterações (*rounds*) do modelo. Normalmente, grande valores para este parâmetro tende a melhorar a performance do

modelo, porém ocorre um aumento significativo de tempo de processamento, principalmente em conjunto de dados maiores.

Tabela VII: Matriz de confusão do conjunto de teste original para o *Gradient Boost*.

Verdade	Predição			
		N	S	V
	N	39876	54	4308
	S	1746	9	82
	V	1821	10	1389

Tabela VIII: Matriz de confusão do conjunto de teste aplicado ao SMOTE para o *Gradient Boost*.

Verdade	Predição			
		N	S	V
	N	27246	8078	8914
	S	360	895	682
	V	730	498	1992

Pela Tabela VII, percebe-se um desempenho um pouco melhor para o *Gradient Boost* em relação às classes N e V. Classe S ainda continua tendo um desempenho baixo. Apenas 9 batimentos da classe S foram classificados corretamente, representando apenas 0,48% do total de batimentos. A classe N apresentou as melhores Se^N e $+P^N$ de 90% e 92%, respectivamente. No cenário com o SMOTE, a Tabela VIII mostra que a classe S começou a apresentar uma melhora no desempenho, tendo 48,72% dos batimentos classificados corretamente. Um aumento de desempenho considerável quando comparado ao *SVM* na mesma configuração. As classes N e V foram classificadas corretamente em sua maioria, mesmo apresentando ainda muitas predições errôneas. As classes N e V obtiveram Se de 62%. A melhor $+P$ foi para a classe N com valor de 96%.

No modelo *Gradient Boost*, o SMOTE apresentou melhoras de desempenho para as classes S e V de 9844% e 43,41%, respectivamente. Para a classe N, houve uma queda de desempenho de 31,67%.

C. XGradient Boost

Para este modelo, os hiperparâmetros configurados manualmente foram $n_estimator = 1000$ para o conjunto original e $n_estimator = 200$ para o conjunto com SMOTE. Essa diferença de valores ocorreu devido o tempo de processamento no conjunto com SMOTE ser consideravelmente maior. Ainda, foi utilizado $learning_rate = 0,1$.

Tabela IX: Matriz de confusão do conjunto de teste original para o *XGradient Boost*.

Verdade	Predição			
		N	S	V
	N	39474	119	4645
	S	1720	2	115
	V	1520	8	1692

Tabela X: Matriz de confusão do conjunto de teste aplicado ao SMOTE para o *XGradient Boost*.

		Predição		
		N	S	V
Verdade	N	31288	5467	7483
	S	578	708	551
	V	757	486	1977

Para o conjunto de dados original, o *XGradient Boost* apresentou desempenho favorável para as classes N e V, tendo a classe V apresentado $+P$ de 26%, ou seja, apesar de ter realizado bastante previsões corretas, o modelo também realizou bastante previsões errôneas. A classe S ainda continua sendo um grande desafio para o modelo, apresentando apenas 2 previsões corretas, conforme a Tabela IX.

Os resultados com o conjunto de dados com o SMOTE apresentado pela Tabela X, o *XGradient Boost* apresentou um melhor desempenho em relação ao conjunto original. Em relação às previsões corretas de cada classe, a classe N teve uma queda de 20,74%, a classe S teve um aumento de 35300% e a classe V teve um aumento de 16,84%. Com isso, para as classes minoritárias S e V, o modelo obteve Se de 39% e 61%, respectivamente. Por outro lado, a $+P$ dessas classes apresentou desempenho abaixo de 20%. A classe N apresentou as melhores Se e $+P$ de 96% e 71%, respectivamente.

D. Rede Neural Artificial

Conforme descrito na Seção IV-D2, a estrutura de uma rede neural artificial varia de acordo com o número de neurônios utilizados, permitindo assim a construção de diversas redes neurais artificiais diferentes. Neste trabalho foi utilizado uma estrutura simples de rede neural com 3 camadas conforme mostrado na Fig. 10. A camada de entrada apresenta 56 neurônios correspondente ao conjunto de 56 características de cada batimento. A camada oculta apresenta 10 neurônios e por último, a camada de saída com 3 neurônios representando as 3 classes (N, S, V) de classificação dos batimentos.

A construção da rede neural artificial foi realizada pela biblioteca *Keras* do python através da classe *Sequential*, sendo a forma mais simples de construção por meio de agrupamento de camadas. A função de ativação *Rectifier Linear Unit - (ReLU)* foi utilizada na camada oculta e a *softmax* na camada de saída. A ativação *softmax* permite a classificação por meio de probabilidades separadas para cada classe, sendo a classe com maior probabilidade rotulada ao batimento. A camada *Dense* foi utilizada na construção da rede neural, permitindo que todos os neurônios se conectem com todos os neurônios da próxima camada.

O modelo foi treinado com otimizador *Adam*, função objetivo *categorical crossentropy* e *learning rate* = $1e - 3$. O número de épocas (*epochs*) foi configurado para que o modelo fosse treinado enquanto a função objetivo não apresentasse melhoria durante 10 épocas consecutivas. Logo, o modelo utilizou 19 épocas para o conjunto de dados original e 164 épocas para o conjunto de dados com SMOTE.




Fig. 10: Rede neural artificial proposta.

Tabela XI: Matriz de confusão do conjunto de teste original para a rede neural artificial.

		Predição		
		N	S	V
Verdade	N	44238	0	0
	S	1837	0	0
	V	3220	0	0

Tabela XII: Matriz de confusão do conjunto de teste aplicado ao SMOTE para a rede neural artificial.

		Predição		
		N	S	V
Verdade	N	23617	13762	6859
	S	265	1246	326
	V	593	986	1641

A Tabela XI referente ao conjunto original, mostra que a rede neural artificial classificou todos os batimentos como pertencentes à classe N. Isso fez com que a $+P$ e Se das classes S e V ficassem iguais a zero. Logo, o desempenho do modelo para o conjunto original não apresentou resultados satisfatórios, uma vez que a quantidade de batimentos pertencentes à classe N é muito superior em relação às classes S e V, ocasionando nas previsões errôneas.

O cenário apresenta uma melhora nos resultados com a aplicação do SMOTE para balanceamento dos dados. Pela Tabela XII, percebe-se que as classes S e V apresentaram previsões corretas de 67,82% e 50,96% em relação ao total de batimentos, permitindo obter Se de 68% e 51%, respectivamente. Para a classe N, a rede neural artificial obteve 53,38% de previsões corretas em relação ao total de batimentos e Se de 53%. Portanto, o SMOTE apresentou uma contribuição favorável ao desempenho da rede neural artificial, principal-

Tabela XIII: Performance dos modelos em relação ao conjunto de teste (DS2) do conjunto de dados do MIT-BIH original

Modelos	Acc	N			S			V		
		+P ^N	Se ^N	F _s ^N	+P ^S	Se ^S	F _s ^S	+P ^V	Se ^V	F _s ^V
Gradient Boosting	84	92	90	91	12	-	1	24	43	31
XGradient Boosting	84	92	89	91	2	-	-	26	53	35
SVM	90	90	100	95	-	-	-	-	-	-
Rede Neural Artificial	90	90	100	95	-	-	-	-	-	-

Tabela XIV: Performance dos modelos em relação ao conjunto de teste (DS2) do conjunto de dados do MIT-BIH com SMOTE.

Modelos	Acc	N			S			V		
		+P ^N	Se ^N	F _s ^N	+P ^S	Se ^S	F _s ^S	+P ^V	Se ^V	F _s ^V
Gradient Boosting	61	96	62	75	9	49	16	17	62	27
XGradient Boosting	69	96	71	81	11	39	17	20	61	30
SVM	8	85	2	3	-	-	-	6	96	12
Rede Neural Artificial	54	96	53	69	8	68	14	19	51	27

mente para as classes minoritárias S e V, as quais geralmente são os maiores desafios para modelos de classificação em aprendizado máquina.

Diante dos resultados apresentados, o SMOTE apresentou um ganho significativo nos desempenhos dos modelos analisados, principalmente relacionado ao desempenho das classes minoritárias S e V do conjunto de dados. As Tabelas XIII e XIV resumem as métricas extraídas juntamente com a acurácia de cada modelo, confirmando assim a contribuição do SMOTE para os modelos propostos. Os resultados mostram que tomar a acurácia como principal métrica de desempenho torna os resultados bastante enviesados, uma vez que um bom desempenho em apenas uma classe faz com que a acurácia seja alta.

Considerando a sensibilidade (*Se*) como a métrica de maior peso para a escolha do melhor modelo, uma vez que pretende-se classificar corretamente todas as batimentos, principalmente os que contém algum tipo de arritmia, o *Gradient Boost* foi o modelo que apresentou o melhor desempenho em duas das três classes analisadas. O modelo apresentou *Se* de 49% para a classe S e 62% para a classe V, perdendo apenas para o *XGradient Boost*, o qual apresentou 71% de *Se* na classe N. Isso mostra também que modelo baseados em técnicas *ensembles* de aprendizado de máquina pode melhorar o desempenho dos modelos de classificação de arritmias em ECG.

Como trabalho futuro, propõe-se o uso de uma rede neural artificial mais robusta como as tradicionais redes neurais convolucionais artificiais bastante presentes na literatura. Ainda, propõe-se o uso de outras técnicas de extração de características dos sinais de ECG e outras técnicas de balanceamento de dados com objetivo de melhorar a caracterização das classes minoritárias do banco de dados atuais.

VII. CONCLUSÕES

Neste trabalho, foi proposto um modelo de classificação automática de arritmia baseado em transformação discreta Wavelet (*Discrete Wavelet Transform - DWT*) como técnica de redução de ruídos e extração de características de sinais

de ECG. Inicialmente, os sinais do conjunto de dados foram normalizados e decompostos em sub-bandas de frequências de acordo com a função geradora *wavelet sym20* e removido os ruídos utilizando um *thresholding* de 0.4. Ainda, com a função geradora *db14* foi gerado 56 características para cada sinal de ECG. Por fim, quatro classificadores (*Support Vector Machine (SVM)*, *XGradientBoost*, *GradientBoost* e *Redes neurais artificiais*) foram utilizados e comparados de acordo com suas performances na classificação de três classes de arritmias. Como simulação de aplicabilidade em cenários reais, os modelos foram treinados de acordo com o paradigma *inter-patient*. Adicionalmente, a performance de classificação dos modelos foram analisadas separadamente considerando os dados originais e o conjunto de dados aumentados com a técnica SMOTE.

Os resultados mostraram melhor performance de classificação para o conjunto de dados aumentados pela técnica SMOTE. O modelo *GradientBoost* foi o que apresentou a melhor performance entre os modelos analisados, principalmente na *Se* em relação às classe minoritárias S e V. Os resultados ainda mostraram que a acurácia nem sempre descreve o melhor desempenho dos modelos, pois um alto desempenho em apenas uma classe pode ocasionar resultados enviesados. As técnicas que envolvem a combinação de algoritmos de aprendizado de máquina (*ensembles*) mostraram que podem ajudar na melhoria do desempenho de projetos de classificação de arritmias de cenários reais.

AGRADECIMENTOS

Agradecimentos ao incentivo e suporte da Universidade Federal de Ouro Preto e FAPEMIG e CNPq.

REFERENCES

- [1] W. H. Organization, *Cardiovascular diseases (CVDs)*, WHO, 2021. [Online]. Available: [https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] A. Cohen, *Biomedical Signal Processing*. CRC Press., 1988.

- [3] A. Y. Hannun, P. Rajpurkar, M. Haghpahani, G. H. Tison, C. Bourn, M. P. Turakhia, and A. Y. Ng, "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," *Nature medicine*, vol. 25, no. 1, p. 65, 2019.
- [4] ANSI/AAMI, "Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms," American National Standards Institute, Inc. (ANSI), Association for the Advancement of Medical Instrumentation (AAMI), 2008, ANSI/AAMI/ISO EC57, 1998-(R)2008.
- [5] E. J. d. S. Luz, W. R. Schwartz, G. Cámara-Chávez, and D. Menotti, "Ecg-based heartbeat classification for arrhythmia detection: A survey," *Computer methods and programs in biomedicine*, vol. 127, pp. 144–164, 2016.
- [6] G. B. Moody and R. G. Mark, "The impact of the mit-bih arrhythmia database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001.
- [7] A. L. Goldberger A., H. J. Glass L., M. R. Ivanov PC., M. G. Mietus JE., and S. H. Peng CK., "Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals," pp. e215–e220, 2000.
- [8] P. De Chazal, M. O'Dwyer, and R. B. Reilly, "Automatic classification of heartbeats using ecg morphology and heartbeat interval features," *IEEE transactions on biomedical engineering*, vol. 51, no. 7, pp. 1196–1206, 2004.
- [9] M. K. Das and S. Ari, "Ecg beats classification using mixture of features," *International scholarly research notices*, vol. 2014, 2014.
- [10] G. Garcia, G. Moreira, D. Menotti, and E. Luz, "Inter-patient ecg heartbeat classification with temporal vcg optimized by pso," *Scientific reports*, vol. 7, no. 1, pp. 1–11, 2017.
- [11] W.-H. Jung and S.-G. Lee, "Ecg identification based on non-fiducial feature extraction using window removal method," *Applied Sciences*, vol. 7, no. 11, p. 1205, 2017.
- [12] L. Wang, W. Sun, Y. Chen, P. Li, and L. Zhao, "Wavelet transform based ecg denoising using adaptive thresholding," in *Proceedings of the 2018 7th International Conference on Bioinformatics and Biomedical Science*, 2018, pp. 35–40.
- [13] Y. Wu, R. M. Rangayyan, Y. Zhou, and S.-C. Ng, "Filtering electrocardiographic signals using an unbiased and normalized adaptive noise reduction system," *Medical engineering & physics*, vol. 31, no. 1, pp. 17–26, 2009.
- [14] S. Pongponnari and X.-H. Yu, "An adaptive filtering approach for electrocardiogram (ecg) signal noise reduction using neural networks," *Neurocomputing*, vol. 117, pp. 206–213, 2013.
- [15] M. Rakshit and S. Das, "An efficient ecg denoising methodology using empirical mode decomposition and adaptive switching mean filter," *Biomedical signal processing and control*, vol. 40, pp. 140–148, 2018.
- [16] M. Sarfraz, A. A. Khan, and F. F. Li, "Using independent component analysis to obtain feature space for reliable ecg arrhythmia classification," in *2014 IEEE international conference on bioinformatics and biomedicine (BIBM)*. IEEE, 2014, pp. 62–67.
- [17] T. Wang, C. Lu, Y. Sun, M. Yang, C. Liu, and C. Ou, "Automatic ecg classification using continuous wavelet transform and convolutional neural network," *Entropy*, vol. 23, no. 1, p. 119, 2021.
- [18] F. M. Dias, H. L. Monteiro, T. W. Cabral, R. Naji, M. Kuehni, and E. J. d. S. Luz, "Arrhythmia classification from single-lead ecg signals using the inter-patient paradigm," *Computer Methods and Programs in Biomedicine*, vol. 202, p. 105948, 2021.
- [19] M. Blanco-Velasco, B. Weng, and K. E. Barner, "Ecg signal denoising and baseline wander correction based on the empirical mode decomposition," *Computers in biology and medicine*, vol. 38, no. 1, pp. 1–13, 2008.
- [20] Z. Wang, F. Wan, C. M. Wong, and L. Zhang, "Adaptive fourier decomposition based ecg denoising," *Computers in Biology and Medicine*, vol. 77, pp. 195–205, 2016.
- [21] G. D. Clifford, F. Azuaje, P. McSharry *et al.*, *Advanced methods and tools for ECG data analysis*. Artech house Boston, 2006.
- [22] C. Ye, B. V. Kumar, and M. T. Coimbra, "Heartbeat classification using morphological and dynamic features of ecg signals," *IEEE Transactions on Biomedical Engineering*, vol. 59, no. 10, pp. 2930–2941, 2012.
- [23] J. Zheng, J. Zhang, S. Danioko, H. Yao, H. Guo, and C. Rakovski, "A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients," *Scientific data*, vol. 7, no. 1, pp. 1–8, 2020.
- [24] K. Sternickel, "Automatic pattern recognition in ecg time series," *Computer methods and programs in biomedicine*, vol. 68, no. 2, pp. 109–115, 2002.
- [25] S. Mousavi and F. Afghah, "Inter-and intra-patient ecg heartbeat classification for arrhythmia detection: a sequence to sequence deep learning approach," in *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2019, pp. 1308–1312.
- [26] P. Yang, D. Wang, W.-B. Zhao, L.-H. Fu, J.-L. Du, and H. Su, "Ensemble of kernel extreme learning machine based random forest classifiers for automatic heartbeat classification," *Biomedical Signal Processing and Control*, vol. 63, p. 102138, 2021.
- [27] V. Mondéjar-Guerra, J. Novo, J. Rouco, M. G. Penedo, and M. Ortega, "Heartbeat classification fusing temporal and morphological information of ecgs via ensemble of classifiers," *Biomedical Signal Processing and Control*, vol. 47, pp. 41–48, 2019.
- [28] K. N. Rajesh and R. Dhuli, "Classification of imbalanced ecg beats using re-sampling techniques and adaboost ensemble classifier," *Biomedical Signal Processing and Control*, vol. 41, pp. 242–254, 2018.
- [29] H. Shi, H. Wang, Y. Huang, L. Zhao, C. Qin, and C. Liu, "A hierarchical method based on weighted extreme gradient boosting in ecg heartbeat classification," *Computer methods and programs in biomedicine*, vol. 171, pp. 1–10, 2019.
- [30] P. Rajpurkar, A. Y. Hannun, M. Haghpahani, C. Bourn, and A. Y. Ng, "Cardiologist-level arrhythmia detection with convolutional neural networks," *arXiv preprint arXiv:1707.01836*, 2017.
- [31] G. B. Moody and R. G. Mark, "The mit-bih arrhythmia database on cd-rom and software for use with it," in *[1990] Proceedings Computers in Cardiology*. IEEE, 1990, pp. 185–188.
- [32] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "Smote: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.
- [33] S. Kadambe, R. Murray, and G. F. Boudreaux-Bartels, "Wavelet transform-based qrs complex detector," *IEEE Transactions on biomedical Engineering*, vol. 46, no. 7, pp. 838–848, 1999.
- [34] Q. Zhao and L. Zhang, "Ecg feature extraction and classification using wavelet transform and support vector machines," in *2005 International Conference on Neural Networks and Brain*, vol. 2. IEEE, 2005, pp. 1089–1092.
- [35] S. Mallat, *A wavelet tour of signal processing*. Elsevier, 1999.
- [36] R. Ramos, B. Valdez-Salas, R. Zlatev, M. Schorr Wiener, and J. M. Bastidas Rull, "The discrete wavelet transform and its application for noise removal in localized corrosion measurements," *International Journal of Corrosion*, vol. 2017, 2017.
- [37] V. Vapnik, *The nature of statistical learning theory*. Springer science & business media, 1999.
- [38] C. Cortes and V. Vapnik, "Support-vector networks," *Machine learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [39] B. Schölkopf, A. J. Smola, F. Bach *et al.*, *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2002.
- [40] Y. Özbay, R. Ceylan, and B. Karlik, "A fuzzy clustering neural network architecture for classification of ecg arrhythmias," *Computers in Biology and Medicine*, vol. 36, no. 4, pp. 376–388, 2006.
- [41] T. Ince, S. Kiranyaz, and M. Gabbouj, "A generic and robust system for automated patient-specific classification of ecg signals," *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 5, pp. 1415–1426, 2009.