

Reconhecimento de padrões em séries temporais de ECG

Rafael Francisco de Oliveira

Departamento de Computação

Universidade Federal de Ouro Preto - UFOP

Conselho Nacional de Desenvolvimento Científico e Tecnológico - CNPq

Email: rafael.fo@aluno.ufop.edu.br

Abstract—Doenças cardíacas (CVDs), do inglês *cardiovascular diseases*, são uma das principais causas de morte no planeta. Estima-se que mais de 75% dos casos acontecem em países pobres e em desenvolvimento e, segundo a OMS, uma estimativa de 17.9 milhões de pessoas morreram de CVDs em 2019, representando 32% das mortes globais. Isto se deve ao fato de que, medidas de prevenção, aparentemente, não estão sendo adequadas. O principal exame para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG) e, por meio dele, é possível detectar arritmias cardíacas. O processo de identificação e classificação de arritmias pode ser muito exaustivo para um ser humano e, sujeito a erros, uma vez que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. A automatização deste processo torna-se desejável e atualmente, técnicas de inteligência artificial são analisadas para esta finalidade. Dentre as técnicas de inteligência artificial investigadas, técnicas como redes neurais artificiais (*Artificial Neural Networks (ANNs)*) e *Support-Vector Machines (SVMs)* têm obtido resultados significativos para detecção dos padrões associados com os diversos tipos de arritmias cardíacas. Neste trabalho, propõe-se um método de classificação automática de arritmias em ECG baseada em *Wavelet Transform (WT)*, redes neurais artificiais e SVM. WT é usada para decompor os sinais ECG obtendo vários componentes no domínio tempo-frequência e, ANN e SVM são usados para classificação dos ECG. Ainda, pretende-se aplicar o paradigma *inter-patient* no desenvolvimento metodológico e experimental e testes comparativos entre os classificadores.

Keywords: Classificação de arritmia; Classificação de ECG; Wavelet Transform; Arritmia; Eletrocardiograma; Inter-Patient.

I. INTRODUÇÃO

De acordo com a Organização Mundial de Saúde (OMS), doenças cardíacas são a principal causa de morte no planeta. E apesar de boa parte das doenças cardíacas poderem ser diagnosticadas com antecedência, o número de casos continuam a crescer. Estima-se que mais de 75% dos casos acontecem em países pobres e em desenvolvimento e, segundo a OMS, uma estimativa de 17.9 milhões de pessoas morreram de CVDs em 2019, representando 32% das mortes globais [1]. Isto se deve ao fato de que, medidas de prevenção, aparentemente, não estão sendo adequadas, por isso o diagnóstico precoce é de fundamental importância.

O principal exame para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG). Segundo [2], o ECG foi um dos primeiros sinais estudados pelas técnicas de processamento de sinais biomédicos e até os dias de hoje é a técnica

mais utilizada no diagnóstico de doenças do coração. Isto é possível por causa da simplicidade do exame, o qual é um processo não-invasivo.

Um dos problemas cardíacos detectável pelo exame de ECG são as arritmias. Arritmias são batimentos cardíacos anormais ou irregulares. Têm-se duas categorias de arritmias: as arritmias formadas por um único batimento cardíaco irregular, denominadas de arritmias morfológicas, e as arritmias formadas por um conjunto irregular de batimentos, denominadas arritmias rítmicas.

O processo de identificação e classificação de arritmias pode ser muito exaustivo para um ser humano e, ainda sujeito a erros, visto que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. Portanto, existe a necessidade de estudos por soluções que mitigue esses erros.

Uma alternativa consiste no uso de inteligência artificial para classificação automática destes padrões. Atualmente, métodos baseados em aprendizagem de máquina, do inglês *machine learning*, têm se tornado populares e obtido resultados expressivos [3], porém, ainda há muito espaço para melhorias, especialmente quando leva em consideração uma avaliação mais rigorosa [4].

Uma grande dificuldade para o uso em campo prático de técnicas estado-da-arte, como as baseadas em aprendizagem de máquina, é a sua integração com os equipamentos médicos. Para que estas técnicas possam ser consideradas para o uso em monitores de sinais vitais ou desfibriladores, por exemplo, o projeto e análise de experimentos deve obedecer a norma ANSI/AAMI EC57:1998/(R)2008 [4].

Ainda, para que elas possam ser definitivamente embarcadas em equipamentos médicos, deve-se seguir outras normas e boas práticas de desenvolvimento para construção de software para equipamentos médicos-hospitalares. Manter a conformidade com todas as normas e boas práticas é ainda um grande obstáculo para a introdução de novas técnicas na indústria. Ainda, métodos publicados na literatura que não levam em conta normas e boas práticas de avaliação e desenvolvimento tendem a ser superestimados e assim, sem grande valor prático para fabricantes de equipamentos médicos [5].

O processo de classificação de arritmias divide-se em quatro partes principais: pré-processamento, segmentação do sinal, extração de características e classificação. Na etapa

de pré-processamento, aplica-se filtros com o objetivo de eliminar interferência de ruídos no sinal ECG, o que afeta diretamente na acurácia do modelo proposto. Na etapa de segmentação, realiza-se a detecção das ondas R (Fig. 2) e segmenta-se cada batimento. Na etapa de extração de características, diversos métodos são propostos na literatura, dentre eles a *Wavelet Transform*, que permite obter uma representação multirresolução de alguns padrões da estrutura do sinal no domínio tempo-frequência. Em seguida, aplica-se algum método classificador, como as redes neurais artificiais, que são treinadas com o vetor de características extraído do sinal.

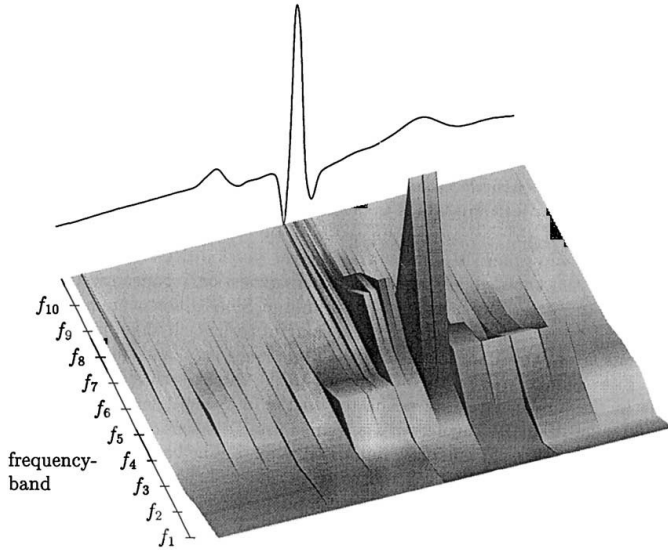


Fig. 1: Representação de multirresolução de um ECG pelos coeficientes *wavelet* [6].




Fig. 2: Batimento normal de ECG, derivação II [7].

Neste projeto, propõe-se a classificação automática de arritmia dos sinais de eletrocardiograma, por meio da técnica

Wavelet Transform durante a etapa de extração de características e redes neurais artificiais e SVM para classificação. A proposta é realizar um teste comparativo entre os métodos em relação ao desempenho. Pretende-se, ainda, basear nas normas ANSI/AAMI EC57:1998/(R) para o desenvolvimento metodológico e experimental. Os experimentos foram validos utilizando o *dataset* PhysioNet MIT-BIH [8], [9] usando o paradigma *inter-patient* proposto por [10].

O trabalho é organizado como segue. Seção II mostra uma breve revisão da literatura referente às etapas necessárias para um sistema de classificação de ECG, bem como os métodos existentes. A metodologia proposta para a classificação de ECG é descrita na Seção III. Além disso, na Seção IV, a descrição dos experimentos e resultados são mostrados. Na Seção V, as discussões dos resultados obtidos e comparações com outros trabalhos da literatura são apresentados. Finalmente, as observações finais são reportadas na Seção VI.

II. TRABALHOS RELACIONADOS

Um sistema completo de classificação e reconhecimento de arritmias em ECG pode ser dividido em três partes principais: 1) pré-processamento, 2) segmentação do sinal, 3) extração de características e 4) classificação do batimento conforme a Fig. 3.

A detecção de arritmias baseadas na classificação de ECG tornou-se um tópico de pesquisa muito popular na literatura nos últimos anos [5]. Os métodos tradicionais de classificação utilizam de características para a classificação dos batimentos cardíacos, algumas como sendo, por exemplo, o intervalo RR, *wavelet*, amplitude, complexo QRS, onda P, duração, etc., extraídas do sinal como mostrado na Fig. 2.

Para melhor extrair informações úteis do sinal, algumas técnicas são aplicadas. Na etapa de pré-processamento, a remoção de ruído do sinal, como por exemplo, interferência na linha de energia e *baseline wandering*, vários métodos tem sido propostos, como filtros-bandas [11], [12], métodos baseados em *wavelet transform* [13], [14], filtros adaptativo [15], [16], decomposição empírica [17], e análise de componente independente [18]. Deve-se observar que a aplicação excessiva de filtros pode ocasionar na perda de informações úteis para a classificação.

[19] e [20] utilizaram dois filtros de medianas (ou seja, um filtro de mediana de largura de 200 ms e um filtro de mediana de largura de 600 ms) para remoção do *baseline wandering* do sinal, o qual é causado pela respiração ou pelo movimento do paciente. [14] propuseram um método de seleção *wavelet* com limiar adaptativo para redução de ruído em ECG baseado em funções *wavelet*. O limiar foi ajustado dinamicamente utilizando heurística e o número de camadas da decomposição da função *wavelet*. [21] utilizaram modo de decomposição empírica para remoção de altas frequências de ruídos e *baseline wandering*. Em [22], a decomposição adaptativa de Fourier foi o método aplicado para diminuir o ruído dos sinais de ECG.

Após a aplicação dos filtros no pré-processamento, é preciso segmentar os batimentos individuais do sinal de ECG. Isto

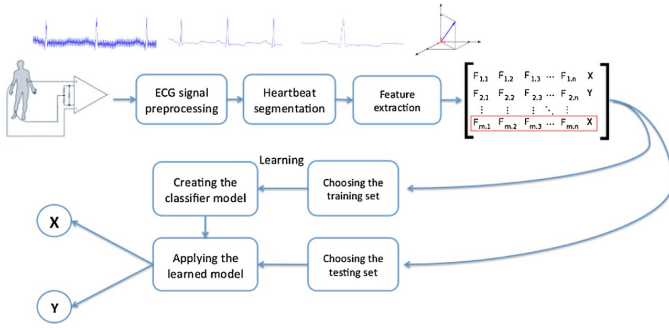


Fig. 3: Diagrama de um sistema de classificação de arritmia [5].

requer detecção das ondas QRS e pontos fiduciais dos batimentos [19]. No entanto, trabalhos na literatura não executam esta etapa e usam a posição da onda R rotulada no conjunto de dados [5]. Uma proposta diferente é proposta em [23], onde os autores propuseram a adição artificial de um tremor (*jitter*) na posição da onda R. Este tremor foi modelado utilizando média zero e desvio padrão de 5 amostras, isto é, 13,9 ms. Uma ilustração da segmentação é mostrada da Fig. 4.

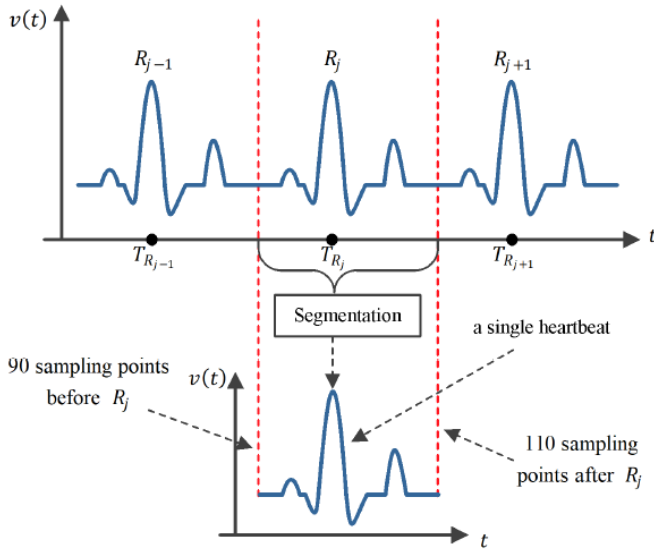


Fig. 4: Exemplo de segmentação de sinal ECG [19].

Para que ocorra a distinção das classes de batimentos, características são necessárias e precisam ser extraídas dos sinais de ECG. Com isso, várias características e métodos têm sido utilizados na literatura. Em [10], os autores combinaram características rítmicas, duração de onda e características morfológicas. Em [24], os autores utilizaram mais de 200 características no classificador utilizado, tais como idade, gênero, características do canal II do ECG além de características de todos os 12 canais presente no banco de dados utilizado.

[14] propuseram um método de seleção de características baseado em transformação *wavelet* com limiar adaptativo com objetivo de reduzir o ruído do sinal de ECG. [17] pro-

puseram uma metodologia utilizando o modo de decomposição empírica (*empirical mode decomposition (EMD)*) e filtro de comutação média adaptativa (*adaptive switching mean filter (ASMF)*) para decompor os sinais ECG como um conjunto de funções intrínsecas (*intrinsic mode functions (IMFs)*) com base na complexidade do sinal para remover a interferência de ruído.

A *Wavelet Transform* mostrada na Fig. 1 pode ser utilizada para extrair características, uma vez que a mesma realiza uma decomposição adaptativa em tempo-frequência do sinal de ECG padrão apresentado. Pela representação multirresolução é possível descrever a estrutura do sinal por apenas alguns coeficientes do domínio *Wavelet* [6].

Os métodos de classificação que utilizam técnicas de aprendizagem de máquina apresentam limitações de performance quando lidam com conjuntos de dados desbalanceados. Em particular, estes tipos de conjuntos de dados atingem um valor preditivo positivo baixo e sensibilidade para as classes com menor tamanho de amostra contidas no mesmo, ocasionando em resultados enviesados. Percebe-se pela Tabela I, as classes F, Q e SVEB do conjuntos de dados do MIT-BIH são as classes que apresentam o menor percentual de registros.

Adicional ao problema de conjuntos de dados desbalanceados, métodos que não levam em consideração normas de separação de dados em conjuntos de treinamento e teste tendem a obter resultados altos e enviesados. Alguns trabalhos na literatura tem avaliados os paradigmas *intra-patient* e *inter-patient* [25] com o objetivo de tornar o cenário mais realista em termos do mecanismo de validação. No paradigma *intra-patient*, o conjunto de treino e teste incluem dados de um mesmo paciente, enquanto que no paradigma *inter-patient* proposto por [10], uma avaliação mais realista é utilizada quando os conjuntos de treino e teste são formados por dados de pacientes diferentes. Este último permite uma generalização no modelo ideal para cenário no mundo real. Com isso, neste trabalho será avaliado o método sob o paradigma *inter-patient*.

Após a extração das características do sinal de ECG, um classificador de aprendizado de máquina é treinado utilizando o vetor de características. A escolha do classificador será de acordo com o problema a ser tratado. A literatura apresenta vários modelos, tais como SVM [26], random forests [27], AdaBoost [28], XGBoost [29] e redes neurais artificiais [30].

Tabela I: Divisão de tipos de batimento no conjunto de dados do MIT-BIH

Grupo AAMI	Batimentos	% do total	# batimentos
Normal	N, e, j, L, R	82,78	90631
SVEB	A, a, J, S	2,54	2781
VEB	V, E	6,60	7236
F	F, e, j, L, R	0,73	803
P (marco-passo)	/, f	7,32	8010
Q	U	0,03	33
Total		100	109494

O modelo de redes neurais artificiais apresentou crescente interesse pela comunidade científica, pois uma de suas vantagens das redes neurais é sua capacidade de generalização e

aplicações. Porém, os padrões encontrados no treinamento de modelo precisam prover uma caracterização suficientemente eficiente para que o modelo adapte à entrada de novos dados.

III. METODOLOGIA

IV. RESULTADOS

V. DISCUSSÕES

VI. CONCLUSÕES

AGRADECIMENTOS

O autor gostaria de agradecer o suporte da Universidade Federal de Ouro Preto e FAPEMIG.

REFERENCES

- [1] W. H. Organization, *Cardiovascular diseases (CVDs)*, WHO, 2021. [Online]. Available: <https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>
- [2] A. Cohen, *Biomedical Signal Processing*. CRC Press., 1988.
- [3] A. Y. Hannun, P. Rajpurkar, M. Haghighpanahi, G. H. Tison, C. Bourn, M. P. Turakhia, and A. Y. Ng, "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," *Nature medicine*, vol. 25, no. 1, p. 65, 2019.
- [4] ANSI/AAMI, "Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms," American National Standards Institute, Inc. (ANSI), Association for the Advancement of Medical Instrumentation (AAMI), 2008, ANSI/AAMI/ISO EC57, 1998-(R)2008.
- [5] E. J. d. S. Luz, W. R. Schwartz, G. Cámara-Chávez, and D. Menotti, "Ecg-based heartbeat classification for arrhythmia detection: A survey," *Computer methods and programs in biomedicine*, vol. 127, pp. 144–164, 2016.
- [6] K. Sternickel, "Automatic pattern recognition in ecg time series," *Computer methods and programs in biomedicine*, vol. 68, no. 2, pp. 109–115, 2002.
- [7] G. D. Clifford, F. Azuaje, P. McSharry *et al.*, *Advanced methods and tools for ECG data analysis*. Artech house Boston, 2006.
- [8] G. B. Moody and R. G. Mark, "The impact of the mit-bih arrhythmia database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001.
- [9] A. L. Goldberger A., H. J. Glass L., M. R. Ivanov PC., M. G. Mietus JE., and S. H. Peng CK., "Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals," pp. e215–e220, 2000.
- [10] P. De Chazal, M. O'Dwyer, and R. B. Reilly, "Automatic classification of heartbeats using ecg morphology and heartbeat interval features," *IEEE transactions on biomedical engineering*, vol. 51, no. 7, pp. 1196–1206, 2004.
- [11] M. K. Das and S. Ari, "Ecg beats classification using mixture of features," *International scholarly research notices*, vol. 2014, 2014.
- [12] G. Garcia, G. Moreira, D. Menotti, and E. Luz, "Inter-patient ecg heartbeat classification with temporal vcg optimized by pso," *Scientific reports*, vol. 7, no. 1, pp. 1–11, 2017.
- [13] W.-H. Jung and S.-G. Lee, "Ecg identification based on non-fiducial feature extraction using window removal method," *Applied Sciences*, vol. 7, no. 11, p. 1205, 2017.
- [14] L. Wang, W. Sun, Y. Chen, P. Li, and L. Zhao, "Wavelet transform based ecg denoising using adaptive thresholding," in *Proceedings of the 2018 7th International Conference on Bioinformatics and Biomedical Science*, 2018, pp. 35–40.
- [15] Y. Wu, R. M. Rangayyan, Y. Zhou, and S.-C. Ng, "Filtering electrocardiographic signals using an unbiased and normalized adaptive noise reduction system," *Medical engineering & physics*, vol. 31, no. 1, pp. 17–26, 2009.
- [16] S. Pongponnari and X.-H. Yu, "An adaptive filtering approach for electrocardiogram (ecg) signal noise reduction using neural networks," *Neurocomputing*, vol. 117, pp. 206–213, 2013.
- [17] M. Rakshit and S. Das, "An efficient ecg denoising methodology using empirical mode decomposition and adaptive switching mean filter," *Biomedical signal processing and control*, vol. 40, pp. 140–148, 2018.
- [18] M. Sarfraz, A. A. Khan, and F. F. Li, "Using independent component analysis to obtain feature space for reliable ecg arrhythmia classification," in *2014 IEEE international conference on bioinformatics and biomedicine (BIBM)*. IEEE, 2014, pp. 62–67.
- [19] T. Wang, C. Lu, Y. Sun, M. Yang, C. Liu, and C. Ou, "Automatic ecg classification using continuous wavelet transform and convolutional neural network," *Entropy*, vol. 23, no. 1, p. 119, 2021.
- [20] F. M. Dias, H. L. Monteiro, T. W. Cabral, R. Naji, M. Kuehni, and E. J. d. S. Luz, "Arrhythmia classification from single-lead ecg signals using the inter-patient paradigm," *Computer Methods and Programs in Biomedicine*, vol. 202, p. 105948, 2021.
- [21] M. Blanco-Velasco, B. Weng, and K. E. Barner, "Ecg signal denoising and baseline wander correction based on the empirical mode decomposition," *Computers in biology and medicine*, vol. 38, no. 1, pp. 1–13, 2008.
- [22] Z. Wang, F. Wan, C. M. Wong, and L. Zhang, "Adaptive fourier decomposition based ecg denoising," *Computers in Biology and Medicine*, vol. 77, pp. 195–205, 2016.
- [23] C. Ye, B. V. Kumar, and M. T. Coimbra, "Heartbeat classification using morphological and dynamic features of ecg signals," *IEEE Transactions on Biomedical Engineering*, vol. 59, no. 10, pp. 2930–2941, 2012.
- [24] J. Zheng, J. Zhang, S. Danioko, H. Yao, H. Guo, and C. Rakovski, "A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients," *Scientific data*, vol. 7, no. 1, pp. 1–8, 2020.
- [25] S. Mousavi and F. Afghah, "Inter-and intra-patient ecg heartbeat classification for arrhythmia detection: a sequence to sequence deep learning approach," in *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2019, pp. 1308–1312.
- [26] V. Mondéjar-Guerra, J. Novo, J. Rouco, M. G. Penedo, and M. Ortega, "Heartbeat classification fusing temporal and morphological information of ecgs via ensemble of classifiers," *Biomedical Signal Processing and Control*, vol. 47, pp. 41–48, 2019.
- [27] P. Yang, D. Wang, W.-B. Zhao, L.-H. Fu, J.-L. Du, and H. Su, "Ensemble of kernel extreme learning machine based random forest classifiers for automatic heartbeat classification," *Biomedical Signal Processing and Control*, vol. 63, p. 102138, 2021.
- [28] K. N. Rajesh and R. Dhuli, "Classification of imbalanced ecg beats using re-sampling techniques and adaboost ensemble classifier," *Biomedical Signal Processing and Control*, vol. 41, pp. 242–254, 2018.
- [29] H. Shi, H. Wang, Y. Huang, L. Zhao, C. Qin, and C. Liu, "A hierarchical method based on weighted extreme gradient boosting in ecg heartbeat classification," *Computer methods and programs in biomedicine*, vol. 171, pp. 1–10, 2019.
- [30] P. Rajpurkar, A. Y. Hannun, M. Haghighpanahi, C. Bourn, and A. Y. Ng, "Cardiologist-level arrhythmia detection with convolutional neural networks," *arXiv preprint arXiv:1707.01836*, 2017.