

# Reconhecimento automático de padrões em séries temporais de ECG

Rafael Francisco de Oliveira

Departamento de Computação

Universidade Federal de Ouro Preto - UFOP

Conselho Nacional de Desenvolvimento Científico e Tecnológico - CNPq

Email: rafael.fo@aluno.ufop.edu.br

**Abstract**—O processo de identificação e classificação de arritmias em eletrocardiogramas (ECG) pode ser muito exaustivo para um ser humano e, sujeito a erros, uma vez que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. A automatização do processo torna-se desejável e atualmente, técnicas de inteligência artificial são aplicadas com esse objetivo. Portanto, um modelo de classificação automática de arritmias em ECG é proposto utilizando *Wavelet Transformation (WT)* nas etapas de pré-processamento e extração de características e, *Redes neurais artificiais (ANN)* e *Support Vector Machine (SVM)* na etapa de classificação. O modelo será avaliado utilizando o conjunto de dados MIT-BIH de acordo com os padrões da AAMI juntamente com o paradigma *inter-patient* no desenvolvimento metodológico e experimental.

**Keywords:** Classificação de arritmia; AAMI; Wavelet Transform; Arritmia; SVM; Eletrocardiograma; Inter-Patient; Redes neurais artificiais.

## I. INTRODUÇÃO

De acordo com a Organização Mundial de Saúde (OMS), doenças cardíacas são a principal causa de morte no planeta. Embora boa parte das doenças cardíacas possam ser diagnosticadas com antecedência, o número de casos continua a crescer. Estima-se que mais de 75% dos casos acontecem em países pobres e em desenvolvimento e 17,9 milhões de pessoas morreram de doenças cardíacas em 2019, representando 32% das mortes globais [1]. Isso se deve ao fato de que, medidas de prevenção, aparentemente, não estão sendo adequadas, por isso o diagnóstico precoce é de fundamental importância.

O principal exame para diagnóstico de doenças cardíacas é chamado Eletrocardiograma (ECG). Segundo Cohen [2], o ECG foi um dos primeiros sinais estudados pelas técnicas de processamento de sinais biomédicos e até os dias de hoje é a técnica mais utilizada no diagnóstico de doenças do coração. Isto é possível por causa da simplicidade do exame, o qual é um processo não-invasivo.

Um dos problemas cardíacos detectável pelo exame de ECG são as arritmias. Arritmias são batimentos cardíacos anormais ou irregulares. Há duas categorias de arritmias: as arritmias formadas por um único batimento cardíaco irregular, denominadas de arritmias morfológicas, e as arritmias formadas por um conjunto irregular de batimentos, denominadas arritmias rítmicas.

O processo de identificação e classificação de arritmias pode ser muito exaustivo para um ser humano e, ainda sujeito a

erros, visto que seria necessário uma análise de batimento a batimento em horas ou até mesmo dias de registros de ECG capturados. Portanto, existe a necessidade de estudos por soluções que mitigue esses erros. Uma alternativa consiste no uso de inteligência artificial para classificação automática dos padrões de arritmia. Atualmente, métodos baseados em aprendizagem de máquina, do inglês *machine learning*, tornaram-se bastante populares, obtendo resultados expressivos [3]. Porém, ainda há muito espaço para melhorias, especialmente quando se considera uma avaliação mais rigorosa [4].

Uma grande dificuldade para o uso em campo prático de técnicas estado-da-arte, como as baseadas em aprendizagem de máquina, é a sua integração com os equipamentos médicos. Para que as soluções propostas possam ser utilizadas em monitores de sinais vitais ou desfibriladores, por exemplo, o projeto e análise de experimentos deve obedecer a norma ANSI/AAMI EC57:1998/(R)2008 [4] da *Association for the Advancement of Medical Instrumentation (AAMI)*. Além disso, deve-se seguir outras normas e boas práticas de desenvolvimento para construção de software para equipamentos médicos-hospitalares. Manter a conformidade com todas as normas e boas práticas é ainda um grande obstáculo para a introdução de novas técnicas na indústria. As abordagens publicadas na literatura que não seguem esses requisitos tendem a ser superestimados e assim, sem grande valor prático para fabricantes de equipamentos médicos [5].

O processo de classificação de arritmias divide-se em quatro partes principais: pré-processamento, segmentação do sinal, extração de características e classificação. Na etapa de pré-processamento, são aplicados filtros com o objetivo de eliminar a interferência de ruídos no sinal ECG, o que afeta diretamente a acurácia de modelos propostos. Na etapa de segmentação, é realizada a detecção das ondas R (Fig. 1) e a segmentação de cada batimento. Na etapa de extração de características, são propostos diversos métodos na literatura, dentre eles a *Wavelet Transform (WT)*, que permite obter uma representação multirresolução de alguns padrões da estrutura do sinal no domínio tempo-frequência. Em seguida, aplica-se algum método classificador, como as redes neurais artificiais, que são treinadas com o vetor de características extraído do sinal.

Neste projeto, propõe-se a classificação automática de arritmia a partir de sinais de eletrocardiograma. Para isso, a

técnica *Wavelet Transform* (WT) é utilizada nas etapas de pré-processamento e extração de características e a classificação é realizada por meio de redes neurais artificiais e SVM. A proposta é realizar um teste comparativo entre os métodos em relação ao desempenho. Pretende-se, ainda, seguir as normas ANSI/AAMI EC57:1998/(R) para o desenvolvimento metodológico e experimental. Os experimentos foram validados utilizando o *dataset* PhysioNet MIT-BIH [6], [7] utilizando paradigma *inter-patient* proposto por De Chazal et al. [8].

O trabalho é organizado como segue. Seção II mostra uma breve revisão da literatura referente às etapas necessárias para um sistema de classificação de ECG, bem como os métodos existentes. Seção III define o conjunto de dados utilizado para avaliação do modelo. A metodologia proposta para a classificação de ECG é descrita na Seção IV. Além disso, na Seção V, a descrição dos experimentos e resultados são mostrados. Na Seção VI, as discussões dos resultados obtidos e comparações com outros trabalhos da literatura são apresentados. Finalmente, as observações finais são reportadas na Seção VII.

## II. TRABALHOS RELACIONADOS

Um sistema completo de classificação e reconhecimento de arritmias em ECG pode ser dividido em quatro partes principais: 1) pré-processamento, 2) segmentação do sinal, 3) extração de características e 4) classificação.

Para melhor extrair informações úteis do sinal, algumas técnicas são aplicadas. A etapa de pré-processamento é onde ocorre a remoção de ruído do sinal, como por exemplo, interferência na linha de energia e *baseline wandering*. Vários métodos tem sido propostos, como filtros-bandas [9], [10], métodos baseados em *wavelet transform* [11], [12], filtros adaptativo [13], [14], decomposição empírica [15], e análise de componente independente [16]. Deve-se observar que a aplicação excessiva de filtros pode ocasionar perda de informações úteis para a classificação. T. Wang et al. [17] e Dias et al. [18] utilizaram dois filtros de medianas, um deles com largura de 200 ms e outro com largura de 600 ms para remoção do *baseline wandering* do sinal, ocasionado pela respiração ou pelo movimento do paciente. L. Wang et al. [12] propuseram um método de seleção *wavelet* com limiar adaptativo para redução de ruído em ECG baseado em funções *wavelet*. O limiar foi ajustado dinamicamente utilizando heurística e o número de camadas da decomposição da função *wavelet*. Blanco-Velasco et al. [19] utilizaram modo de decomposição empírica para remoção de altas frequências de ruídos e *baseline wandering*. Em [20], a decomposição adaptativa de Fourier foi escolhida para diminuir o ruído dos sinais de ECG.

A detecção de arritmias com base na classificação de ECG tornou-se um tópico de pesquisa muito popular na literatura nos últimos anos [5]. Os métodos tradicionais utilizam características extraídas do sinal para a classificação dos batimentos cardíacos, como, por exemplo, o intervalo RR, *wavelet*, amplitude, complexo QRS, onda P, duração, etc. Os principais pontos e intervalos de um sinal ECG são mostrados na Fig. 1.




Fig. 1: Batimento normal de ECG da derivação II [21].

Após a aplicação dos filtros no pré-processamento, segmentam-se os batimentos individuais do sinal de ECG. Isso requer detecção das ondas QRS e pontos fiduciais dos batimentos [17]. No entanto, trabalhos na literatura não executam essa etapa e usam a posição da onda R rotulada no conjunto de dados [5]. Uma abordagem diferente é proposta em [22], onde os autores propuseram a adição sintética de um tremor (*jitter*) na posição da onda R. O tremor é modelado com média zero e desvio padrão de 5 amostras, isto é, 13,9 ms.

A identificação dos padrões de batimentos ocorre a partir de características extraídas dos sinais de ECG. Com isso, várias características e métodos têm sido utilizados na literatura. Em [8], os autores combinaram características rítmicas, duração de onda e características morfológicas. Em [23], os autores utilizaram mais de 200 características no classificador utilizado, tais como idade, gênero, características do canal II do ECG além de características extraídas dos 12 canais presente no banco de dados utilizado. L. Wang et al. [12] propuseram um método de seleção de características baseado em transformação *wavelet* com limiar adaptativo, visando reduzir o ruído do sinal de ECG. Rakshit e Das [15] propuseram uma metodologia utilizando o modo de decomposição empírica (*empirical mode decomposition* (EMD)) e filtro de comutação média adaptativa (*adaptive switching mean filter* (ASMF)) para decompor os sinais ECG, gerando um conjunto de funções intrínsecas (*intrinsic mode functions* (IMFs)) com base na complexidade do sinal para remover a interferência de ruído. A *Wavelet Transform* pode ser utilizada para extrair características, uma vez que a mesma realiza uma decomposição adaptativa em tempo-frequência do sinal de ECG padrão apresentado. Pela representação multirresolução é possível descrever a estrutura do sinal por apenas alguns coeficientes do domínio *Wavelet* [24]. A Fig. 2 exemplifica a decomposição de um sinal ECG em dez sub-bandas de frequências.

Os métodos de classificação que utilizam técnicas de apren-




Fig. 2: Representação de multiresolução de um sinal ECG pelos coeficientes *wavelet* [24].

dizagem de máquina apresentam limitações de performance quando lidam com conjuntos de dados desbalanceados. Em particular, esses conjuntos de dados atingem um valor preditivo positivo baixo. Além disso, baixa sensibilidade para as classes com menor quantidade de amostras, ocasionando em resultados enviesados. Adicional ao problema de conjuntos de dados desbalanceados, métodos que não levam em consideração normas de separação de dados em conjuntos de treinamento e teste tendem a obter resultados altos e enviesados.

Com o objetivo de tornar o modelo em desenvolvimento mais robusto e adaptável a um cenário no mundo real, alguns trabalhos na literatura exploraram dois paradigmas de validação de dados: *intra-patient* e *inter-patient* [25]. No paradigma *intra-patient*, o conjunto de treino e teste é formado por dados de um mesmo paciente, enquanto que no paradigma *inter-patient*, proposto por De Chazal et al. [8], o conjunto de treino e teste são obtidos de pacientes diferentes. Esse último permite uma generalização mais próxima de um cenário do mundo real.

Mousavi e Afghah [25] propuseram um modelo baseado em redes neurais de aprendizado profundo (*deep learning*) aplicado com metodologia *sequence to sequence* e algoritmo SMOTE para balanceamento das classes durante a etapa de treinamento. Os autores avaliaram o modelo com trabalhos estado-da-arte da literatura de acordo com os paradigmas apresentados anteriormente. O modelo proposto obteve performance superior em relação a todos os trabalhos comparados, em ambos paradigmas, obtendo acurácia de 99,92% no paradigma *intra-patient* e 99,53% no paradigma *inter-patient*.

Para avaliar melhor o desempenho real do classificador, garantir uma competição justa entre modelos propostos na literatura e seguir práticas recomendadas pela AAMI [4], alguns trabalhos [8], [10], [18], [26] fizeram uso do paradigma *inter-patient* com o mesmo objetivo. Logo, este trabalho propõe o uso do mesmo paradigma no desenvolvimento metodológico.

Após a extração das características do sinal de ECG, um classificador de aprendizado de máquina é treinado utilizando um vetor de características. A escolha do classificador ocorre de acordo com o problema a ser tratado. Na literatura há vários modelos, tais como SVM [27], random forest [26], AdaBoost [28], XGBoost [29] e redes neurais artificiais [30].

O modelo de redes neurais artificiais apresenta crescente interesse pela comunidade científica, pois uma de suas vantagens é a capacidade de generalização e aplicações. Porém, os padrões encontrados no treinamento dos modelos precisam prover uma caracterização suficientemente eficiente para que se adapte à entrada de novos dados.

### III. CONJUNTO DE DADOS

Em razão das propostas de modelos de classificação para o avanço da instrumentação médica [4], será utilizado o conjunto de dados de arritmias PhysioNet MIT-BIH [6], [7], [31] para treinamento e validação da metodologia proposta, permitindo assim uma possível comparação com outras metodologias da literatura. O conjunto de dados do MIT-BIH é composto por 48 registros de sinais de ECG de 30 minutos de 47 pacientes diferentes amostrados a frequência de 360 Hz. Cada sinal contém duas derivações: derivação V e derivação II. Normalmente, a derivação II é a mais utilizada nas metodologias da literatura. De forma similar, nos experimentos deste trabalho, a derivação II será utilizada.

Seguindo recomendações da AAMI, quatro registros são excluídos do conjunto de dados por possuírem batimentos artificiais. De Chazal et al. [8] recomenda a divisão do conjunto de dados em dois conjuntos: treino (DS1) e teste (DS2) conforme a Tabela I. Essa divisão faz parte do paradigma *inter-patient* utilizado neste trabalho, onde o conjunto de treino e teste apresentam conjuntos de registros diferentes.

O conjunto de dados do MIT-BIH contém informações dos tipos de batimentos e a localização do pico R, mediante o consenso de classificação de dois cardiologistas. Dentre os 18 tipos de batimentos, a AAMI também recomenda o agrupamento dos batimentos em cinco grupos principais: *Normal (N)*, *Supraventricular ectopic beat (S)*, *Ventricular ectopic beat (V)*, *Fusion beat (F)* e *Unknown beat (Q)*. A Tabela II resume o agrupamento dos batimentos dos dados do MIT-BIH.

Tabela I: Distribuição dos registros do MIT-BIH em conjunto de treino e teste.

Conjunto	Registros
DS1 (Treino)	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223, e 230.
DS2 (Teste)	100, 103, 105, 111, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233, e 234.

Tabela II: Agrupamento de tipos de batimento no conjunto de dados do MIT-BIH.

Grupo AAMI	Batimentos	% do total	# batimentos
<i>Normal (N)</i>	N, e, j, L, R	89,47	90125
<i>Supraventricular ectopic beat (S)</i>	A, a, J, S	2,76	2781
<i>Ventricular ectopic beat (V)</i>	V, E	6,96	7009
<i>Fusion beat (F)</i>	F	0,80	803
<i>Unknown beat (Q)</i>	P, f, U	0,01	15
<b>Total</b>		<b>100</b>	<b>100733</b>

#### IV. METODOLOGIA

A seguir, é apresentado a metodologia proposta para classificação automática de arritmias em ECG. O diagrama da Fig. 3 mostra as etapas do sistema de classificação proposto: pré-processamento, segmentação, extração de características e classificação.

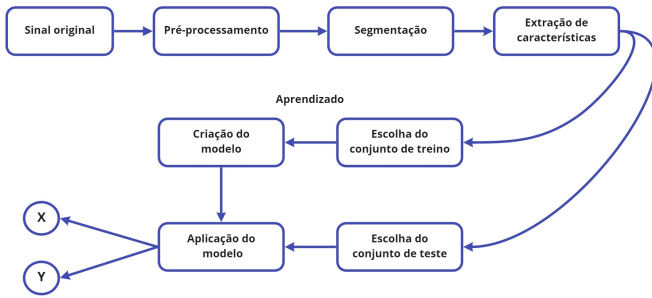


Fig. 3: Diagrama do sistema de classificação de arritmia [5].

##### A. Pré-processamento

O conjunto de dados do MIT-BIH é bastante desbalanceado e o número de batimentos amostrados de cada grupo de arritmia são completamente diferentes, conforme mostra a Tabela II. Este desbalanceamento causa sobreajuste (*overfitting*) no modelo de classificação em relação a classe majoritária e consequentemente diminuindo a acurácia nas classes minoritárias. Por outro lado, há ainda a presença de ruídos e/ou interferências nos sinais de ECG causados, por exemplo, por movimento do corpo ou cabos de energias defeituosos, os quais prejudicam a performance de extração de características e classificação do sistema. Outro desafio, diz respeito a extração de batimentos dos sinais de ECG. No pré-processamento, utiliza-se dois processos para contornar os problemas apresentados anteriormente.

1) *Sobreamostragem*: Nesse trabalho, para tratar o problema do alto desbalanceamento do conjunto de dados do MIT-BIH e evitar o sobreajuste do classificador, será utilizado a técnica *Synthetic Minority Over-sampling Technique - SMOTE* nas classes minoritárias. O SMOTE utiliza a similaridade entre as amostras existentes para produzir os dados sintéticos. Para isso, a classe minoritária é super-amostrada tomando cada amostra de classe minoritária e introduzindo exemplos sintéticos de qualquer e/ou todos os  $k$  vizinhos mais próximos da classe minoritária  $k$  de forma randômica [32]. Portanto,

após as etapas de pré-processamento e da divisão dos dados em conjunto de treinamento e teste (80%-20%, respectivamente) utilizando *10-fold* na validação cruzada, o SMOTE é aplicado no conjunto de treinamento para evitar o uso de amostras sintéticas na realização da avaliação do modelo. Para evitar sobreamostragem irregular, a técnica SMOTE é aplicada apenas nas classes S, F e Q.

2) *Remoção de ruído*: Sinais de ECG apresentam diversos ruídos provenientes de diversas formas, como movimentos dos músculos, da respiração do paciente ou mau contato dos elétrodos na pele do paciente, os quais podem diminuir a acurácia da classificação. Para isso, será aplicada a técnica *Wavelet Transform (WT)* baseada em *thresholding*.

##### \*IMAGEM DA REMOÇÃO

*Wavelet Transform (WT)* é uma série composta por operações de escalonamento e deslocamento em base de uma função geradora chamada de *mother wavelet*, podendo ser contínuas ou discretas. WT pode representar uma informação local do sinal de ECG no domínio do tempo e frequência para ajustar as sub-bandas de alta e baixa frequência separadamente através das janelas de tempo e de frequência, para atingir o objetivo de eliminação de ruído dos sinais de ECG [12]. WT tem sido utilizada em diferentes metodologias, como detecção de batimentos [33] e extração de características [34].

A *Continuous Wavelet Transformation (CWT)* realiza o escalonamento e deslocamentos de forma contínua enquanto que a *Discrete Wavelet Transform (DWT)* realiza as operações de forma discreta. As fórmulas (1) e (2) [35] representam as funções contínuas e discretas, respectivamente:

$$X_w(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \bar{\psi} \left( \frac{t-b}{a} \right) dt \quad (1)$$

$$\psi_{j,k}(t) = \frac{1}{\sqrt{2^j}} \psi \left( \frac{t - k2^j}{2^j} \right) \quad (2)$$

onde  $x(t)$  é o sinal original,  $\bar{\psi}(t)$  é a função *wavelet* contínua,  $[(a > 0) a \in R^{+*}, j]$  são fatores de escalonamento e  $[b, j]$  são fatores de deslocamento. Como a CWT tem alta correlação, a DWT é mais utilizada nas aplicações de redução de ruídos [12], a qual é utilizada nesse trabalho.

A DWT decompõe o sinal de ECG iterativamente, e em cada iteração, o sinal é decomposto a partir do valor médio da frequência do sinal de entrada. Para isso, utiliza-se de filtros de passagem alta (FPA) e filtros de passagem baixa (FPB). A Fig. 4 mostra um processo de decomposição de um sinal em duas camadas da WT.




Fig. 4: Processo de decomposição do sinal em duas camadas [12].

O sinal de entrada  $S_0$  é filtrado na sub-banda de alta frequência  $D_1$  e na sub-banda de baixa frequência  $A_1$ , e então a  $A_1$  é filtrado novamente em sub-bandas de alta e baixa frequência,  $D_1$  e  $D_2$ , respectivamente. O processo de decomposição do sinal  $S_0$  pode ser resumido pela fórmula (3):

$$S_0 = D_1 + D_2 + A_2 \quad (3)$$

Após a decomposição, os coeficientes podem perceber sinal de amplitude maiores do que o ruído em certa medida, definida por um limiar (*threshold*). Valores acima desse limiar são removidos, reduzindo assim, os ruídos do sinal.

### B. Segmentação

Antes da classificação, é necessário a segmentação do sinal ECG em batimentos individuais. Isto requer a identificação da onda QRS e pontos fiduciais do batimento. No entanto, vários métodos são desenvolvidos na literatura para detecção desses pontos fiduciais com altas acurácias. Nesse trabalho, a segmentação compõe por utilizar a localização do pico R anotada no conjunto de dados do MIT-BIH, segmentar o sinal em séries de batimentos extraíndo  $n$  amostras antes e  $n$  amostras depois do pico R, e realizar o registro do tipo de batimento de acordo com as anotações do MIT-BIH. Para cada batimento, utiliza-se tamanho fixo de 300 amostras do sinal de ECG. Uma ilustração da segmentação é mostrada na Fig. 5.

### C. Extração de características

Os batimentos são compostos por diferentes frequências. Por isso, nessa etapa de extração de características, os batimentos são convertidos para o domínio tempo-frequência utilizando a CWT. Como os diferentes tipos de batimentos exibem características de frequência diferentes, essa diferença de comportamento é capaz gerar características para cada batimento e posteriormente tornam-se um vetor de características para entrada de um classificador.

### \*ANALISAR QUAIS FEATURES SÃO MELHORES

### D. Classificação

Após aplicar todas as etapas de pré-processamento, segmentação e extração de características, as características obtidas são enviadas para um classificador. Nesse trabalho, é abordado dois classificadores: *Support Vector Machine* (SVM) e redes neurais artificiais (ANN).

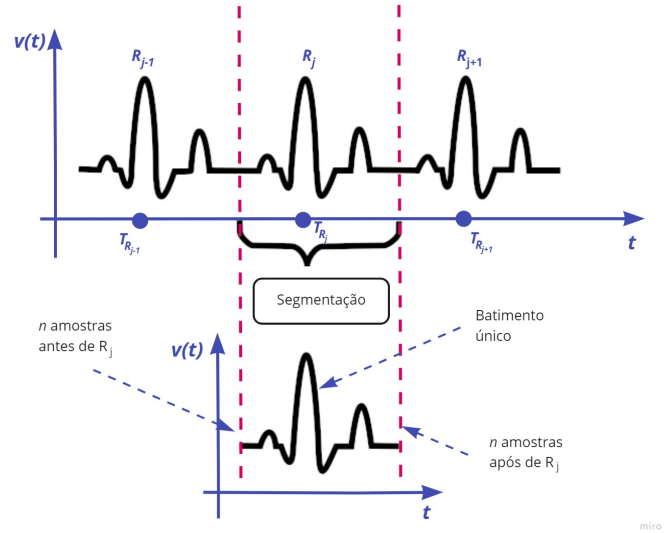


Fig. 5: Exemplo de segmentação de sinal ECG [17].

1) *Support Vector Machine*: Proposto por Vapnik [36], SVM são métodos que constroem classificadores a partir da criação de hiper-planos em um espaço  $n$ -dimensional, isto é, desenha “linhas” em um espaço  $n$ -dimensional que são capazes de separar exemplos de diferentes classes [37], [38]. Estes hiper-planos são criados com o auxílio de pontos localizados nas bordas dos conjuntos, chamados *vetores de suporte*.

O SVM constrói primeiramente um hiperplano ou um conjunto de hiperplanos em um espaço  $n$ -dimensional. Uma separação ideal entre os dados é obtida através do hiperplano que possui a maior distância ao ponto de dados de treinamento mais próximo de qualquer classe, denominada de *margem funcional*. Isso ocorre, porque quanto maior a margem, menor o erro de generalização do classificador.

Normalmente, os dados em análise não são facilmente separáveis em hiperplanos, uma vez que os dados, em sua maioria, são não-lineares. Como solução, propõe-se que os dados em espaço original sejam mapeados em um hiper espaço  $n$ -dimensional ou espaço em dimensão superior para facilitar a separação dos dados.

Os mapeamentos usados pelos esquemas SVM são projetados para garantir que os produtos escalares de pares de vetores de dados de entrada possam ser calculados facilmente em termos das variáveis no espaço original, definindo-as em termos de uma função *kernel*  $k(x, y)$ .

Os hiperplanos no espaço de dimensão superior são definidos como o conjunto de pontos cujo produto escalar com um vetor naquele espaço é constante, onde tal conjunto de vetores é um conjunto ortogonal de vetores que define um hiperplano.

Os vetores que definem os hiperplanos podem ser escolhidos para serem combinados linearmente com parâmetros  $\alpha_i$  dos vetores de características  $x_i$  do conjunto de dados. Escolhido o hiperplano, os pontos  $x$  no espaço de características são mapeados no hiperplano pela equação:



$$\sum_i \alpha_i k(x_i, x) = \text{constant} \quad (4)$$

Quando  $k(x, y)$  na Equação (4) torna-se pequeno à medida que  $y$  torna-se longe de  $x$ , cada termo na soma mede o grau de proximidade do ponto de teste  $x$  ao ponto do conjunto de dados correspondente  $x_i$ .

Desta forma, a soma da Equação (4) pode ser usada para medir a proximidade relativa de cada ponto de teste aos pontos de dados originados em um ou outro conjunto a ser discriminado.

2) *Redes Neurais Artificiais (ANN)*: Pode-se pensar nas ANNs como sendo um sistema computacional contendo um grande número de neurônios artificiais. Por sua vez, estes neurônios podem ser vistos como processadores simples, massivamente paralelizados e organizados de forma inspirada a uma rede neural biológica. Esses neurônios artificiais também podem ser generalizados para melhor atender às necessidades de um problema em específico, formando-se diversas arquiteturas de redes.

As arquiteturas mais utilizadas para classificação de arritmias são *Multilayer Perceptron (MLP)* e *Probabilistic Neural Network (PNN)*. Esses tipos de redes podem ser combinados a fim de maximizar a eficiência da classificação. Há trabalhos que propuseram, por exemplo, uma rede híbrida neuro-fuzzy [39] e redes neurais otimizadas evolucionárias com *particle swarm optimization (PSO)* [40].

Redes neurais permitem adaptação de forma mais específica de acordo com o problema através da organização das camadas intermediárias e funções de ativações dentro da rede. Este tipo de rede também permite realizar a transformação necessária e as operações de agrupamento automática e simultaneamente e reconhecer grupos complexos e não lineares no hiperespaço. Apesar dessas vantagens, redes neurais requerem tempo de processamento, *hardware* e grande conjunto de dados dependendo do tipo de problema em estudo.




Fig. 6: Rede neural artificial com um neurônio.

Formalmente, todos os tipos de redes neurais apresentam a mesma unidade de processamento: um neurônio artificial. Esse neurônio artificial possui várias entradas, que correspondem às conexões sinápticas com outras unidades similares a ele, e uma saída, cujo valor depende diretamente da somatória ponderada de todas as saídas dos outros neurônios a esse conectado.

Pela Fig. 6 mostra uma rede neural artificial de um neurônio, onde as constantes de ponderação  $w_i$  representam as conexões sinápticas biológicas que intermeiam a interação

entre neurônios vizinhos,  $x_i$  é o estímulo proveniente do neurônio vizinho  $i$ , e o somatório  $\sum$  representa o estímulo global (com as devidas ponderações relativas) recebido pelo neurônio de todos os seus vizinhos.

De acordo com o valor da variável somatório  $\sum$  e com a função de ativação  $f()$  à qual essa variável é aplicada, a rede fornecerá uma saída em resposta aos estímulos  $x_i$  conforme representado pela equação:

$$y = f\left(\sum_{i=1}^m x_i w_i\right) \quad (5)$$

Uma rede neural artificial com vários neurônios é mostrada na Fig. 7. A rede apresentada contém uma camada de entrada com 4 neurônios, uma camada oculta com 5 neurônios, outra camada oculta com 7 neurônios e por último, uma camada com 3 neurônios. A rede fornecerá três saídas  $[y_1, y_2, y_3]$  de acordo com a resposta dos estímulos de entrada  $[x_1, x_2, x_3, x_4]$  ao longo da rede dado pela Equação (5).




Fig. 7: Rede neural artificial com vários neurônios.

## V. RESULTADOS

## VI. DISCUSSÕES

## VII. CONCLUSÕES

## AGRADECIMENTOS

O autor gostaria de agradecer o suporte da Universidade Federal de Ouro Preto e FAPEMIG.

## REFERENCES

- [1] W. H. Organization, *Cardiovascular diseases (CVDs)*, WHO, 2021. [Online]. Available: [https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] A. Cohen, *Biomedical Signal Processing*. CRC Press., 1988.
- [3] A. Y. Hannun, P. Rajpurkar, M. Haghpanahi, G. H. Tison, C. Bourn, M. P. Turakhia, and A. Y. Ng, "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," *Nature medicine*, vol. 25, no. 1, p. 65, 2019.

- [4] ANSI/AAMI, "Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms," American National Standards Institute, Inc. (ANSI), Association for the Advancement of Medical Instrumentation (AAMI), 2008, ANSI/AAMI/ISO EC57, 1998-(R)2008.
- [5] E. J. d. S. Luz, W. R. Schwartz, G. Cámara-Chávez, and D. Menotti, "Ecg-based heartbeat classification for arrhythmia detection: A survey," *Computer methods and programs in biomedicine*, vol. 127, pp. 144–164, 2016.
- [6] G. B. Moody and R. G. Mark, "The impact of the mit-bih arrhythmia database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001.
- [7] A. L. Goldberger A., H. J. Glass L., M. R. Ivanov PC., M. G. Mietus JE., and S. H. Peng CK., "Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals," pp. e215–e220, 2000.
- [8] P. De Chazal, M. O'Dwyer, and R. B. Reilly, "Automatic classification of heartbeats using ecg morphology and heartbeat interval features," *IEEE transactions on biomedical engineering*, vol. 51, no. 7, pp. 1196–1206, 2004.
- [9] M. K. Das and S. Ari, "Ecg beats classification using mixture of features," *International scholarly research notices*, vol. 2014, 2014.
- [10] G. Garcia, G. Moreira, D. Menotti, and E. Luz, "Inter-patient ecg heartbeat classification with temporal vcg optimized by pso," *Scientific reports*, vol. 7, no. 1, pp. 1–11, 2017.
- [11] W.-H. Jung and S.-G. Lee, "Ecg identification based on non-fiducial feature extraction using window removal method," *Applied Sciences*, vol. 7, no. 11, p. 1205, 2017.
- [12] L. Wang, W. Sun, Y. Chen, P. Li, and L. Zhao, "Wavelet transform based ecg denoising using adaptive thresholding," in *Proceedings of the 2018 7th International Conference on Bioinformatics and Biomedical Science*, 2018, pp. 35–40.
- [13] Y. Wu, R. M. Rangayyan, Y. Zhou, and S.-C. Ng, "Filtering electrocardiographic signals using an unbiased and normalized adaptive noise reduction system," *Medical engineering & physics*, vol. 31, no. 1, pp. 17–26, 2009.
- [14] S. Pongponnari and X.-H. Yu, "An adaptive filtering approach for electrocardiogram (ecg) signal noise reduction using neural networks," *Neurocomputing*, vol. 117, pp. 206–213, 2013.
- [15] M. Rakshit and S. Das, "An efficient ecg denoising methodology using empirical mode decomposition and adaptive switching mean filter," *Biomedical signal processing and control*, vol. 40, pp. 140–148, 2018.
- [16] M. Sarfraz, A. A. Khan, and F. F. Li, "Using independent component analysis to obtain feature space for reliable ecg arrhythmia classification," in *2014 IEEE international conference on bioinformatics and biomedicine (BIBM)*. IEEE, 2014, pp. 62–67.
- [17] T. Wang, C. Lu, Y. Sun, M. Yang, C. Liu, and C. Ou, "Automatic ecg classification using continuous wavelet transform and convolutional neural network," *Entropy*, vol. 23, no. 1, p. 119, 2021.
- [18] F. M. Dias, H. L. Monteiro, T. W. Cabral, R. Naji, M. Kuehni, and E. J. d. S. Luz, "Arrhythmia classification from single-lead ecg signals using the inter-patient paradigm," *Computer Methods and Programs in Biomedicine*, vol. 202, p. 105948, 2021.
- [19] M. Blanco-Velasco, B. Weng, and K. E. Barner, "Ecg signal denoising and baseline wander correction based on the empirical mode decomposition," *Computers in biology and medicine*, vol. 38, no. 1, pp. 1–13, 2008.
- [20] Z. Wang, F. Wan, C. M. Wong, and L. Zhang, "Adaptive fourier decomposition based ecg denoising," *Computers in Biology and Medicine*, vol. 77, pp. 195–205, 2016.
- [21] G. D. Clifford, F. Azuaje, P. McSharry *et al.*, *Advanced methods and tools for ECG data analysis*. Artech house Boston, 2006.
- [22] C. Ye, B. V. Kumar, and M. T. Coimbra, "Heartbeat classification using morphological and dynamic features of ecg signals," *IEEE Transactions on Biomedical Engineering*, vol. 59, no. 10, pp. 2930–2941, 2012.
- [23] J. Zheng, J. Zhang, S. Danioko, H. Yao, H. Guo, and C. Rakovski, "A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients," *Scientific data*, vol. 7, no. 1, pp. 1–8, 2020.
- [24] K. Sternickel, "Automatic pattern recognition in ecg time series," *Computer methods and programs in biomedicine*, vol. 68, no. 2, pp. 109–115, 2002.
- [25] S. Mousavi and F. Afghah, "Inter-and intra-patient ecg heartbeat classification for arrhythmia detection: a sequence to sequence deep learning approach," in *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2019, pp. 1308–1312.
- [26] P. Yang, D. Wang, W.-B. Zhao, L.-H. Fu, J.-L. Du, and H. Su, "Ensemble of kernel extreme learning machine based random forest classifiers for automatic heartbeat classification," *Biomedical Signal Processing and Control*, vol. 63, p. 102138, 2021.
- [27] V. Mondéjar-Guerra, J. Novo, J. Rouco, M. G. Penedo, and M. Ortega, "Heartbeat classification fusing temporal and morphological information of ecgs via ensemble of classifiers," *Biomedical Signal Processing and Control*, vol. 47, pp. 41–48, 2019.
- [28] K. N. Rajesh and R. Dhuli, "Classification of imbalanced ecg beats using re-sampling techniques and adaboost ensemble classifier," *Biomedical Signal Processing and Control*, vol. 41, pp. 242–254, 2018.
- [29] H. Shi, H. Wang, Y. Huang, L. Zhao, C. Qin, and C. Liu, "A hierarchical method based on weighted extreme gradient boosting in ecg heartbeat classification," *Computer methods and programs in biomedicine*, vol. 171, pp. 1–10, 2019.
- [30] P. Rajpurkar, A. Y. Hannun, M. Haghighpanahi, C. Bourn, and A. Y. Ng, "Cardiologist-level arrhythmia detection with convolutional neural networks," *arXiv preprint arXiv:1707.01836*, 2017.
- [31] G. B. Moody and R. G. Mark, "The mit-bih arrhythmia database on cd-rom and software for use with it," in *[1990] Proceedings Computers in Cardiology*. IEEE, 1990, pp. 185–188.
- [32] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "Smote: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.
- [33] S. Kadambe, R. Murray, and G. F. Boudreaux-Bartels, "Wavelet transform-based qrs complex detector," *IEEE Transactions on biomedical Engineering*, vol. 46, no. 7, pp. 838–848, 1999.
- [34] Q. Zhao and L. Zhang, "Ecg feature extraction and classification using wavelet transform and support vector machines," in *2005 International Conference on Neural Networks and Brain*, vol. 2. IEEE, 2005, pp. 1089–1092.
- [35] S. Mallat, *A wavelet tour of signal processing*. Elsevier, 1999.
- [36] V. Vapnik, *The nature of statistical learning theory*. Springer science & business media, 1999.
- [37] C. Cortes and V. Vapnik, "Support-vector networks," *Machine learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [38] B. Schölkopf, A. J. Smola, F. Bach *et al.*, *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2002.
- [39] Y. Özbay, R. Ceylan, and B. Karlik, "A fuzzy clustering neural network architecture for classification of ecg arrhythmias," *Computers in Biology and Medicine*, vol. 36, no. 4, pp. 376–388, 2006.
- [40] T. Ince, S. Kiranyaz, and M. Gabbouj, "A generic and robust system for automated patient-specific classification of ecg signals," *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 5, pp. 1415–1426, 2009.